

**İSTANBUL TEKNİK ÜNİVERSİTESİ
ELEKTRİK-ELEKTRONİK FAKÜLTESİ**

**YÜKSEK DOĞRULUKLU BATARYA SOC TAHMİN MODELLERİNİN
KARŞILAŞTIRMALI ANALİZİ**

ELEKTRİK MÜHENDİSLİĞİ TASARIMI

Turan Can BÜYÜKKAMACI

ELEKTRİK MÜHENDİSLİĞİ BÖLÜMÜ

MAYIS 2024

ELEKTRİK MÜHENDİSLİĞİ BÖLÜMÜ

**İSTANBUL TEKNİK ÜNİVERSİTESİ
ELEKTRİK-ELEKTRONİK FAKÜLTESİ**

**YÜKSEK DOĞRULUKLU BATARYA SOC TAHMİN MODELLERİNİN
KARŞILAŞTIRMALI ANALİZİ**

ELEKTRİK MÜHENDİSLİĞİ TASARIMI

**Turan Can BÜYÜKKAMACI
(050180012)**

Danışmanı: Dr. Öğr. Üyesi Mehmet Onur GÜLBAHÇE

Bölüme Teslim Edildiği Tarih: 31 Mayıs 2024

ELEKTRİK MÜHENDİSLİĞİ BÖLÜMÜ

MAYIS 2024

ÖNSÖZ

Bu çalışmanın yapılmasında, bilgileri, deneyimleri ve zamanıyla beni her aşamada destekleyen Dr. Öğr. Üyesi Mehmet Onur GÜLBAHÇE'ye, araştırma görevlisi öğretmenlerime ve Arda Akyıldız'a minnettarlığımı ifade etmek isterim. Her zaman yanımda olarak desteklerini esirgemeyen aileme ve inancını benden hiç esirgemeyen nişanlım Berfin Güner'e de şükranlarımı sunarım.

Mayıs 2024

Turan Can Büyükkamacı

İÇİNDEKİLER

Sayfa

ÖZET.....	1
ABSTRACT	1
1. GİRİŞ	3
1.1 Tezin Amacı	4
1.2 Literatür Özeti	4
2. BATARYA SİSTEMLERİ	6
2.1 Genel Batarya Türleri ve Çalışma Prensipleri.....	6
2.1.1 Kurşun-Asit (Pb-Asit) bataryalar	7
2.1.2 Nikel-Kadmiyum (Ni-Cd) bataryalar	7
2.1.3 Nikel-Metal Hidrit (Ni-MH) bataryalar	7
2.1.4 Lityum-İyon (Li-ion) bataryalar	8
2.1.4.1 Lityum Kobalt Oksit (LCO)	9
2.1.4.2 Lityum Manganez Oksit (LMO)	9
2.1.4.3 Lityum Demir Fosfat (LFP)	9
2.1.4.4 Lityum Nikel Kobalt Alüminyum Oksit (NCA)	10
2.1.4.5 Lityum Nikel Kobalt Mangan Oksit (NMC)	10
2.2 Batarya Yönetim Sistemi	11
2.3 Batarya Modelleme	12
2.3.1 Elektrokimyasal model.....	12
2.3.2 Elektrik devre modelleri.....	13
2.3.2.1 RC modeli	13
2.3.2.2 PNGV	13
2.3.2.3 Thevenin modeli	14
2.3.2.4 Değiştirilmiş thevenin modeli	15
3. ŞARJ DURUMU TAHMİNLEME YÖNTEMLERİ	16
3.1 Model Bazlı Şarj Durumu Tahminleme Yöntemi	16
3.1.1 Voltaj tabanlı şarj durumu belirleme.....	16
3.1.2 Coulomb sayma yöntemiyle şarj durumu belirleme	17
3.1.3 Diğer şarj durumu belirleme yöntemleri	18
3.1.3.1 Kalman filtresi	19
3.1.3.2 Genişletilmiş kalman filtresi	19
3.2 Veriye dayalı şarj durumu tahminleme yöntemi	19
3.2.1 Destek vektör makineleri	19
3.2.2 XGBoost.....	19
3.2.3 Derin öğrenme.....	20
3.2.3.1 Yapay sinir ağları	20
3.2.3.2 Evrişimli sinir ağları	21
3.2.3.3 Yinelemeli sinir ağları	22
3.2.3.4 Uzun-Kısa vadeli bellek	23
4. DERİN ÖĞRENME YÖNTEMİYLE ŞARJ DURUMU TAHMİNLEME	24
4.1 Veri Seti	24

4.2	Yapay Sinir Ağları Modelinin Geliştirilmesi	25
4.2.1	Keşifsel Veri Analizi	25
4.2.2	Eğitim ve Test	27
4.2.3	Değerlendirme	30
4.3	Evrişimli Sinir Ağları Geliştirilmesi	32
4.3.1	Keşifsel Veri Analizi	32
4.3.2	Eğitim ve Test	33
4.3.3	Değerlendirme	36
4.4	Yinelemeli Sinir Ağları Geliştirilmesi	37
4.4.1	Keşifsel Veri Analizi	37
4.4.2	Eğitim ve Test	39
4.4.3	Değerlendirme	41
4.5	Uzun-Kısa Vadeli Bellek Sinir Ağları Geliştirilmesi	42
4.5.1	Keşifsel Veri Analizi	42
4.5.2	Eğitim ve Test	43
4.5.3	Değerlendirme	46
5	SONUÇLAR VE TARTIŞMA	48
5.1	Karşılaştırmalı Analiz	48
5.2	Performans Yorumları	48
5.2.1	LSTM'nin Verimi	48
5.2.2	CNN'nin Zorlukları	48
5.2.3	RNN'nin Potansiyeli	49
5.2.4	ANN'nin Basitliği	49
5.3	Sonuçlar	49
6	KAYNAKLAR	50
	53
7	53

KISALTMALAR

ANN	: Artificial Neural Network (Yapay Sinir Ağları (YSA))
BYS	: Batarya Yönetim Sistemi
CC	: Coulumb Sayımı
CNN	: Convolutional Neural Network (Evrişimli Sinir Ağları (ESA))
EDA	: Keşifsel Veri Analizi
EKF	: Genişletilmiş Kalman Filtresi
KF	: Kalman Filtresi
LIB	: Li-ion Batarya
LSTM	: Long Short-Term Memory (Uzun-Kısa Vadeli Bellek (UKVB))
OCV	: Açık Devre Gerilimi
RNN	: Recurrent Neural Networks (Yinelemeli Sinir Ağı (YSA))
SoC	: State of Charge (Şarj Durumu)
SoH	: State of Health (Sağlık Durumu)
SVM	: Destek Vektör Makineleri

ÇİZELGE LİSTESİ

	<u>Sayfa</u>
Çizelge 4.1 : Epoch Kayıpları.....	28
Çizelge 4.2 : Eğitim Veri Seti için Metrikler.....	30
Çizelge 4.3 : Test Veri Seti için Metrikler.....	30
Çizelge 4.4 : Epoch Kayıpları.....	34
Çizelge 4.5 : Test Veri Seti için Metrikler.....	36
Çizelge 4.6 : Epoch Kayıpları.....	39
Çizelge 4.7 : Test Veri Seti için Metrikler.....	41
Çizelge 4.8 : Epoch Kayıpları.....	44
Çizelge 4.9 : Test Veri Seti için Metrikler.....	46

ŞEKİL LİSTESİ

Sayfa

Şekil 2.1 : Lityum iyon pilin deşarj ve şarj süreci [8]	8
Şekil 2.2 : Batarya Yönetim Sistemi'nin Ana Başlıkları [12]	11
Şekil 2.3 : RC Modeli [13]	13
Şekil 2.4 : PNGV Modeli [13]	14
Şekil 2.5 : Thevenin Modeli [13]	14
Şekil 2.6 : Değıştirilmiş Thevenin Modeli [13]	15
Şekil 2.7 : Coulomb Sayım Yöntemi [17]	18
Şekil 2.8 : Yapay Sinir Ağı (YSA) Mimarisi [24]	21
Şekil 2.9 : Evrişimli Sinir Ağı Mimarisi [26]	22
Şekil 2.10 : Yenilemeli Sinir Ağı Mimarisi [30]	23
Şekil 2.11 : Uzun Kısa Vadeli Hafıza Mimarisi [34]	24

YÜKSEK DOĞRULUKLU BATARYA SOC TAHMİN MODELLERİNİN KARŞILAŞTIRMALI ANALİZİ

ÖZET

Elektrikli araçların ve akıllı enerji sistemlerinin artan önemi, batarya yönetiminin etkin bir şekilde yapılmasını zorunlu kılmaktadır. Bu çalışmada, LG M50 tipi Li-ion bataryaların şarj durumu (SoC) tahmininin doğruluğunu artırmak amacıyla farklı makine öğrenimi yöntemleri karşılaştırılmıştır. Yapay Sinir Ağları (ANN), Tekrarlayan Sinir Ağları (RNN), Konvolüsyonel Sinir Ağları (CNN) ve Uzun Kısa Süreli Hafıza (LSTM) ağları bu kapsamda değerlendirilmiştir.

İlk olarak, ANN tabanlı bir tahmin modeli geliştirilmiş ve bu modelle yüksek doğrulukta SoC tahmini yapılabilmektedir. Daha sonra, RNN, CNN ve LSTM modelleriyle yapılan karşılaştırmalı testlerle en uygun model belirlenmeye çalışılmıştır. Her bir yöntemin avantajları ve dezavantajları incelenerek batarya yönetim sistemleri için en iyi yöntemin belirlenmesi hedeflenmiştir.

Araştırma sürecinde, modellerin performansları detaylı bir şekilde analiz edilmiş; işlem gücü gereksinimleri, tahmin doğruluğu ve veri işleme verimliliği gibi kriterler dikkate alınmıştır.

Sonuç olarak, bu çalışma, batarya yönetim sistemlerinde şarj durumunu değerlendirmek için en uygun makine öğrenimi yöntemini belirlemeyi amaçlamaktadır.

ABSTRACT

The growing relevance of electric vehicles and smart energy systems necessitates effective battery management. In this study, the state of charge of Li-ion batteries of the LG M50 type is estimated with greater accuracy. Comparing various machine learning methods, such as Artificial Neural Networks (ANN), Recurrent Neural Networks (RNN), Convolutional Neural Networks (CNN), and Long Short-Term Memory (LSTM) networks, allows us to achieve our goal.

High accuracy SoC value estimation was achieved by the first prediction model created, which was ANN-based. Subsequently, trials were carried out to ascertain the ideal model by comparison with RNN, CNN, and LSTM models. Weighing the benefits and drawbacks of each strategy was important to establish which was best for battery management systems.

During the inquiry, a detailed examination of each model's performance was carried out, taking into account several criteria such processing power needs, prediction accuracy, and data processing efficiency.

Therefore, the purpose of this study is to analyze several machine learning techniques and discover which one works best for assessing the status of charge in battery management systems.

BÖLÜM 1: GİRİŞ

1. GİRİŞ

Son on yılda, yenilenebilir enerji kaynakları ve elektrikli araçların kullanımındaki artış, enerji depolama teknolojilerinin hızla ilerlemesine neden olmuştur. Bu ilerleme, lityum-iyon bataryaların performansının ve güvenilirliğinin optimize edilmesini özellikle önemli hale getirmiştir. Ekonomik ve çevresel açıdan bakıldığında, etkin batarya yönetimi hayati öneme sahiptir. Bu ihtiyacı karşılamak amacıyla, Batarya Yönetim Sistemleri (BMS), Şarj Durumu (SoC) gibi kritik parametreleri sürekli olarak izler ve kontrol eder. Şarj Durumu (SoC), bataryanın mevcut şarj seviyesini gösterir ve bataryanın durumu hakkında önemli bilgiler sunar.

Bu çalışma, LG M50 tipi Li-ion bataryaların Şarj Durumu (SoC) tahmininde farklı makine öğrenimi modellerinin performanslarını karşılaştırmayı amaçlamaktadır. İlk olarak, Yapay Sinir Ağları (ANN) kullanılarak geliştirilen bir tahmin modeli, SoC değerlerini yüksek doğrulukla tahmin edebilmiştir. Ardından, ANN modelinin performansı, Yenilemeli Sinir Ağları (RNN), Evrişimli Sinir Ağları (CNN) ve Uzun Kısa Süreli Hafıza (LSTM) ağları gibi diğer ileri düzey modellerle karşılaştırılmıştır. Bu karşılaştırmalı analiz, batarya yönetim sistemleri için en uygun SoC tahmin metodolojisinin belirlenmesine yardımcı olmuştur.

Bu giriş bölümü, batarya sistemleri ve SoC tahmin yöntemlerinin temellerini özetlemekte, çalışmanın kapsamını ve yöntemlerini tanıtmakta ve araştırmanın yapısal çerçevesini belirlemektedir.

1.1 Tezin Amacı

Bu tezin temel amacı, LG M50 tipi Li-ion bataryaların Şarj Durumu tahmininde kullanılan farklı makine öğrenimi modellerinin doğruluğunu ve etkinliğini karşılaştırmak ve değerlendirmektir. İlk olarak, Yapay Sinir Ağları ile şarj durumu tahmin modelleri geliştirilmiş ve bu modellerin performansı ölçülmüştür. Daha sonra, bu modelin performansı, Yenilemeli Sinir Ağları (RNN), Evrişimli Sinir Ağları (CNN) ve Uzun-Kısa Süreli Hafıza (LSTM) modelleri ile karşılaştırılmıştır. Bu karşılaştırmalı analiz yoluyla, daha etkili ve güvenilir şarj durumu tahmin metodolojileri hakkında derinlemesine bir anlayış geliştirilmiş ve batarya yönetim sistemleri için en uygun yaklaşımlar belirlenmiştir.

Ayrıca, bu tez kapsamında, şarj durumu tahmin modellerinin hassasiyeti ve güvenilirliği üzerinde etkili olan faktörler incelenmiş, bu modellerin güçlü ve zayıf yönleri ortaya konulmuş ve farklı kullanım senaryolarına göre en uygun modeller belirlenmiştir.

1.2 Literatür Özeti

Yenilenebilir enerji kaynakları ve elektrikli araçlarla ilişkili olarak, lityum-iyon bataryaların yönetimi ve performans optimizasyonu, son yıllarda araştırmacıların odak noktası haline gelmiştir. Chen ve arkadaşları (2020), lityum-iyon bataryaların parametrelerinin deneysel tekniklerle nasıl tanımlandığını detaylandırırken, Brosa Planella ve arkadaşları (2021) azaltılmış termal-elektrokimyasal model kullanarak bu bataryalar için bir model geliştirilmesinin sistematik bir yöntemini sunmuştur. Bu yöntemler, şarj durumu tahmini için önemli temeller atmakta ve modelleme doğruluğunu artırmaktadır.

Şarj durumu tahmininde, farklı makine öğrenimi yaklaşımlarının uygulanabilirliği ve etkinliği geniş çapta incelenmiştir. Örneğin, Bhattacharyya ve arkadaşları (2021) tarafından geliştirilen bir CNN tabanlı şarj durumu tahmin modeli, lityum-iyon bataryalar için uygulanmış ve yüksek doğrulukta sonuçlar vermiştir. Öte yandan, Yang ve arkadaşları (2019) tarafından kullanılan geri dönüşlü sinir ağları, şarj durumu tahminlerinde etkin bir alternatif olarak ortaya çıkmıştır.

Batarya yönetim sistemlerinin (BYS) işlevselliği üzerine yapılan araştırmalar da bu alandaki teknolojik gelişmeleri belgelemektedir. Wassem ve arkadaşları (2023), elektrikli araçlar için BYS'nin mevcut durumu ve temel zorluklarını değerlendirirken,

řarj durumu tahmin yöntemlerinin bu sistemlerin işlevselliğinde merkezi bir rol oynadığını vurgulamışlardır.

Bu çalışmaların toplamı, lityum-iyon bataryaların daha doğru ve güvenilir řarj durumu tahmin modelleri geliřtirmeye yönelik süregiden çabaları ortaya koymaktadır. Karşılařtırmaalı analizler ve çeřitli makine öğrenimi modellerinin uygulanması, řarj durumu tahminindeki doğruluđu artırmak ve batarya yönetim sistemlerinin genel performansını iyileřtirmek için kritik öneme sahiptir. Mevcut literatür, batarya teknolojilerinin gelecekteki gelişimine yön vermek için değerli bilgiler sağlamakta ve bu alanda daha fazla araştırma yapılmasının gerekliliğini göstermektedir.

2 BATARYA SİSTEMLERİ

Batarya sistemleri, en basit ifadeyle, enerjinin depolanması ve boşaltılması için etkili bir ortam oluşturmak üzere çalışan birçok bileşenin birleşimidir [1]. Bu bölümde ise genel batarya türleri ve çalışma prensibi, batarya yönetim sistemi (BYS) ve batarya modellemesi işlenmiştir.

2.1 Genel Batarya Türleri ve Çalışma Prensibi

Enerji, günümüzün en büyük sorunlarından biridir; dünya nüfusu ve yaşam standartları yükseldikçe enerji ihtiyacı da artmakta ve sürdürülebilir bir gelecek sağlamak adına, ana enerji kaynağı olan fosil yakıtların kullanımını azaltmamız ve CO2 emisyon seviyelerini korumamız gerekmektedir. Neyse ki, özellikle rüzgar ve güneş enerjisi olmak üzere yenilenebilir kaynaklardan elektrik üretimindeki önemli artış, ulaşımın elektrikleştirilmesine ve fosil yakıtlara olan bağımlılığın azaltılmasına olanak tanıyor. Bu nedenle, mobil uygulamalarda yenilenebilir elektriğin kullanılması için hayati öneme sahip olan enerji depolama sistemleri, elektrikli araçlar ve taşınabilir cihazların vazgeçilmez bir parçası olarak giderek daha fazla dikkat çekiyor [2]

Şu anda tüketici cihazları ve elektrikli otomobillerde en çok kullanılan pil tipi olan lityum-iyon piller, ya da LIB'ler mevcut. Yine de, Li-ion pillerin enerji yoğunluğu, gelecekteki enerji taleplerini karşılamak için yeterli değil. Ayrıca, LIB'lerdeki iki kritik katot bileşeni olan kobalt ve lityumun kıtlığı, gelecekte ciddi bir tedarik sorunu yaratması beklenmekte ve lityumun yüksek reaktifliği bazı güvenlik endişelerini de beraberinde getiriyor. Mevcut Li-ion teknolojilerinin, gelecekte ulaşım ve diğer mobil uygulamalar için gerekli olan enerji depolama kapasitelerini karşılaması olası görünmüyor [2]

Bu yüzden, teorik olarak daha yüksek kapasiteler sunabilen, daha ucuz ve daha bol malzemelerle üretilmiş yeni pil teknolojileri araştırmaları devam etmektedir. "Li-ion ötesi piller" terimi, bu yenilikçi pilleri tanımlamak için kullanılıyor ve Li yerine tek değerlikli (Na ve K) veya çok değerlikli (Zn, Mg, vs.) metallerin kullanıldığı, pozitif elektrot malzemesinin değiştirildiği (metal-hava, Li-S, vs.) veya katı hal elektrolitlerin uygulandığı pilleri ifade ediyor.

Bugüne kadar yapılan pil araştırmaları, kullanılan elektrot ve/veya elektrolit türüne göre pilleri kurşun-asit, nikel-kadmiyum, nikel-metal hidrit, lityum-iyon ve lityum-sülfür piller olarak sınıflandırmıştır[3]

2.1.1 Kurşun-Asit (Pb-Asit) bataryalar

Kurşun, asit bataryaları, PVC kablolar, lehimler ve katot ısıtım tüplerinin camı gibi birçok elektronik bileşende kullanılan önemli bir elementtir. Özellikle kurşun-asit bataryalar, 1859 yılında Fransız fizikçi Gaston Planté tarafından icat edilen ilk ticari şarj edilebilir batarya türü olarak, günümüzde de yaygın olarak kullanılmaktadır [4]

Günümüzde, otomotiv, ulaşım ve telekomünikasyon sektörlerinde en çok kullanılan batarya tipi kurşun-asit bataryalardır.

2.1.2 Nikel-Kadmiyum (Ni-Cd) bataryalar

Nikel (Ni), korozyona ve ısıya karşı dayanıklılığıyla dikkat çeker. Güçlü, sünek ve gümüşü beyaz bir metal olan nikel, yüksek direnç özelliğine sahiptir. Sıklıkla metal alaşımlarının oluşturulmasında kullanılır, çünkü tokluk, çekme dayanımı ve elastik limiti arttırmada önemli bir role sahiptir. Ayrıca, diğer metalleri korozyona karşı korumak için kaplama amacıyla yaygın olarak kullanılmaktadır [3]

İsveçli mucit Waldemar Jungner, 1899 yılında ilk defa Ni-Cd (Nikel-Kadmiyum) batarya sistemini geliştirdi ve bu sistem 1950 yılında Avrupa ve Amerika Birleşik Devletleri'nde üretilmeye başlandı. Ni-Cd bataryaların kullanım alanları arasında acil aydınlatma, Kesintisiz Güç Kaynakları (UPS), güneş fotovoltaikleri, yangın alarm sistemleri, sinyalizasyon ve telekomünikasyon, enstrümantasyon ve süreç kontrolü, elektromanyetik kaldırıcılar (köprülü vinçler) gibi çeşitli uygulamalar bulunmaktadır [5]

2.1.3 Nikel-Metal Hidrit (Ni-MH) bataryalar

Konvansiyonel nikel tabanlı şarj edilebilir sistemlerden farklı olarak, hidrojen depolamak için bir anot kullanan Nickel-Metal Hydride (Ni-MH) batarya sistemi, 1980'lerin sonlarında piyasaya sürülmüş ve hidrojenin geri dönüşümlü olarak depolanabileceği bir malzeme kullanmasıyla öne çıkmaktadır. Güçlü alkali ortamlarda ve çok sayıda şarj/deşarj döngüsü boyunca kararlı olan yeni hidrojen depolama alaşımlarının ortaya çıkışı, bu atılımı mümkün kılmıştır. Ni-MH bataryaları, yüksek şarj vedeşarj gücü kapasitesi ve uzun ömürlü olmaları nedeniyle kurşun-asit bataryalarından daha üstündür, özellikle sürekli yüksekdeşarj gücü, hızlı şarj ve uzun dayanıklılık gerektiren uygulamalarda. Bu özellikler nedeniyle, Ni-MH batarya sistemi hibrit elektrikli araç (HEV) uygulamaları için son derece uygundur [6]


2.1.4 Lityum-İyon (Li-ion) bataryalar

Lityum metal, hafifliği ile öne çıkan, tekrar şarj edilebilir pillerde (mobil telefonlar, dizüstü bilgisayarlar, tabletler vb.) genellikle kullanılır ve ağırlığa karşı yüksek direnci nedeniyle uçaklarda alaşım olarak tercih edilir [7]

Lityum içerikli bataryalar, özellikle yüksek döngü sayıları nedeniyle günümüzde taşınabilir elektronik cihazlarda (mobil telefonlar, dizüstü bilgisayarlar ve tabletler), elektrikli araçlarda ve tıbbi cihazlarda yaygın olarak kullanılmaktadır.

LIB'nin yapısı katot, ayırıcı, elektrolit ve anottan oluşmaktadır. Bu terimlerin tanımlanması deşarj işlemi esas alınarak yapılmaktadır. Diğer bir deyişle, şarj işlemi sırasında anot tarafı katot olarak adlandırılabilir. Anot malzemesi olarak grafit veya bakır akım toplayıcı üzerine uygulanmış karbon kullanılır. Anodun elektron barındırma kapasitesini artırmak için çeşitli kimyasallar uygulanır.

Pozitif elektrot kompozisyonu, lityum kobalt oksit (LiCoO_2), lityum nikel oksit (LiNiO_2) ya da lityum demir fosfat (LiFePO_4) gibi metal oksitlerden meydana gelirken; negatif elektrot kısmında ise titanat ($\text{Li}_4\text{Ti}_5\text{O}_{12}$) ya da karbon bazlı grafitten faydalanılabilir. Lityum bazlı bataryaların çoğunda enerji yoğunluğu daha az olsa da daha yüksek güvenilirlik sunan karbon materyali öncelikli tercih olarak öne çıkar. Elektrolit, lityum tuzları ve organik çözücüler içerir; bu bileşenler iki elektrot arasında konumlanarak iyonların taşınmasını sağlar. Pozitif ve negatif elektrotlar arasındaki izolasyon, bir ayırıcı ile temin edilir. Tüm lityum-iyon piller bu ortak prensip etrafında çalışır [8] Şekil 2.1'de Lityum İyon Pilin Deşarj ve Şarj Süreci gösterilmiştir



Şekil 2.1 : Lityum iyon pilin deşarj ve şarj süreci [9]

Lityum-iyon piller, katotlarını oluşturan materyallere göre çeşitlendirilir ve bu materyallerle adlandırılırlar. Günümüzde, LCO (LiCoO_2), LMO (LiMn_2O_4), NMC ($\text{Li}(\text{Ni}_x\text{Co}_y\text{Mn}_z)\text{O}_2$), LFP (LiFePO_4) ve NCA (LiNiCoAlO_2) gibi piller, tüketici elektroniği, enerji depolama sistemleri ve hareketlilik dahil olmak üzere birçok endüstride geniş çapta kullanılmaktadır [3]

2.1.4.1 Lityum Kobalt Oksit (LCO)

Yüksek özgül enerji (150-190 Wh/kg) ve teknolojik olgunluğu sayesinde, 1991'de geliştirilen ilk lityum-iyon batarya kimyası olan LCO (LiCoO_2 katot ve grafit anot), mobil telefonlar, tabletler ve dizüstü bilgisayarlar gibi taşınabilir elektronik cihazlarda yaygın olarak kullanılmaktadır. Bu cihazlar, 500–1000 tam döngüye karşılık gelen kabul edilebilir bir takvim ömrüne sahiptir. LCO bataryasının en büyük dezavantajı, kobalt oksidin sınırlı termal kararlılığı nedeniyle düşük güvenlik seviyesidir—termal kaçak, sadece 150 °C gibi düşük sıcaklıklarda meydana gelebilir. Bu bataryalar, 2011'den beri Boeing 787 Dreamliner'da ek başlatma ve yedek güç sağlamak için kullanılmıştır. 2013 başlarında, batarya arızaları ve termal kaçak olayları nedeniyle tüm etkilenen uçaklar birkaç ay boyunca uçuşları sürdürememiştir. [10]

2.1.4.2 Lityum Manganez Oksit (LMO)

1996 yılında piyasaya sürülen LMO bataryası, LiMn_2O_4 katodunun üç boyutlu spinel yapısı sayesinde elektrot üzerinde iyon akışını kolaylaştırarak düşük iç direnç sağlar. Bu da nispeten yüksek bir özgül güç elde edilmesine olanak tanır. LMO katotları genellikle grafit veya LTO anotlarla birleştirilir. LCO bataryalara kıyasla, LMO bataryalar tipik olarak 1000-1500 döngü ömrüne sahip olmasına rağmen, 100-140 Wh/kg gibi önemli ölçüde daha düşük bir enerji yoğunluğuna sahiptir. Bununla birlikte, manganez oksidin daha yüksek termal kararlılığı sayesinde LMO bataryaları doğal olarak daha güvenlidir ve termal kaçak yaklaşık 250 °C'de gerçekleşir. Ayrıca, batarya bol miktarda bulunan ve çevre dostu bileşenler kullanır ve kobalt içermez. LMO bataryaları çoğunlukla e-bisikletler, elektrikli aletler ve tıbbi ekipmanlarda kullanılır [10]

2.1.4.3 Lityum Demir Fosfat (LFP)

LFP bataryasında, katot malzemesi olarak LiFePO_4 kullanılırken, anot malzemesi olarak genellikle grafit tercih edilir. Bu batarya, 1999 yılında piyasaya sürüldüğünde,

evre dostu bileşenlerinin bol miktarda bulunabilir olması, uzun ömrü ve doğal güvenliği sayesinde umut verici bir teknoloji olarak görölmüşür [10]

Günümüzdeki LFP bataryaları, 2000 tam döngüye kadar dayanabilmekte, ancak gerçekçi endüstri tahminleri daha uzun bir ömür öngörmektedir. Batarya, geniş bir (%15–%100) Şarj Durumu penceresinde çalışabilmekte ve hücre bu aralıkta sabit bir voltaj koruyarak sürekli işletim imkanı sunmaktadır. Bu avantajlarına rağmen, LFP bataryasının diğer Li-ion kimyalarına kıyasla görece düşük özgül enerjisi (90–140 Wh/kg), başlangıçta elektrikli araç seçeneği olarak dikkat çekmesine rağmen bir dezavantajdır [3]

2.1.4.4 Lityum Nikel Kobalt Alüminyum Oksit (NCA)


1999 yılında NCA kimyası piyasaya sürölmüşür. Bu bataryalar, grafit anot ve LiNiCoAlO_2 katot kullanılarak yapılır. Genellikle NCA katotları %80 nikel, %15 kobalt ve %5 alüminyum içerir. Bu nedenle, LCO bataryalarına kıyasla kobalt bağımlılığı oldukça düşüktür. NCA bataryaları, 1000–1500 tam döngüye dayanabilir ve 200–250 Wh/kg gibi olağanüstü bir özgül enerji ve yüksek bir özgül güç sunar. NCA bataryaları elektrikli araçlarda kullanılmakta olup, yük kaydırma ve yedekleme gibi şebeke bağlantılı uygulamalar için de planlar mevcuttur [10]

2.1.4.5 Lityum Nikel Kobalt Mangan Oksit (NMC)

NMC bataryaları, grafit anot ve LiNiMnCoO_2 katot kullanılarak yapılır. NMC bataryalarının döngü ömrü (1000-2000 döngü) NCA bataryalarından daha yüksektir, ancak enerji yoğunluğu daha düşüktür (genellikle 140-200 Wh/kg). Bataryaların özelliklerini etkilemek ve belirli kullanımlar için özel çözümler oluşturmak amacıyla nikel, mangan ve kobalt oranlarını değiştirmek mümkündür [11].

2.2 Batarya Yönetim Sistemi

Batarya Yönetim Sistemi, Bataryanın güvenlik mekanizması olan bataryanın voltaj, akım ve sıcaklık gibi güvenli işletme parametrelerini korumaktan sorumludur. BYS'nin karmaşıklığı ve batarya kimyasının gereksinimleri, koruma derecesini belirler. Kurşun asit ve nikel kadmiyum gibi eski kimyasallara sahip bataryalar, yüksek iç direnç ve yüksek kendiliğinden deşarj seviyelerine sahiptirler, bu da onları aşırı akım ve aşırı voltaj durumlarına karşı dirençli kılar. Genellikle bir sigortadan başka bir korumaya gerek yoktur. Daha yüksek verimlilik sunmalarına rağmen, kapalı tip kurşun asit (SLA), valf regüle edilen kurşun asit (VRLA) ve nikel metal hidrit (Ni-MH) bataryalar aşırı voltaj, düşük voltaj, aşırı akım ve çok yüksek veya düşük sıcaklıklara daha duyarlıdır. [12] Şekil 2.2’de BYS’nin ana başlıkları gösterilmiştir.



Şekil 2.2 : Batarya Yönetim Sistemi’nin Ana Başlıkları [13]

En önemli Batarya Yönetim Sistemleri; donanım ve yazılımdır.

- **Donanım:** BYS içerisine dahil edilen sensörler, voltaj ve sıcaklık gibi birçok batarya parametresini ölçer ve takip eder. Batarya hücrelerinin aşırı şarj edilmesini, deşarj edilmesini veya aşırı ısınmasını doğru bir şekilde önlemek için her zaman gelişmiş bir güvenlik devresi gereklidir. Her hücrenin sıcaklığını belirlenen aralıkta tutmak için bir ısı yönetim sistemi gereklidir.

BYS, hücrelerin voltajını takip etmek için potansiyel durum cihazı kullanır. BYS içinde bir trans-alıcı, verileri aktarır, izler ve gönderir. Kablosuz veya akıllı şarj teknolojilerindeki en son gelişmeler, batarya ve şarj cihazı arasında verilerin kolaylıkla paylaşılmasını sağlar [13]

- **Yazılım:** BYS'nin donanım ve yazılım işlevselliğini yöneten merkezi sistem, oldukça bilinen bir unsurdur. Bu sistem, BYS'ye entegre edilen sensörlerin durumunu hesaplar ve operasyonları kontrol etmenin yanı sıra değerlendirmeler de yapar. Hücresinin verimli çalışması için en önemli bileşenler, arıza tespiti ve durum değerlendirmesidir. BMS'deki yazılım sistemi, batarya hücrelerinden gelen çevrimiçi verileri inceleyerek bu görevleri yerine getirir [13]

2.3 Batarya Modelleme

Batarya modellemesinde pek çok yöntem kullanılmaktadır. Bu çalışmada batarya özelliklerini doğru bir şekilde tahmin etmek için, model tabanlı tahmin, batarya modellemesini gerektirmektedir. Bataryaların simülasyonu için elektrokimyasal model ya da daha genel bir ifadeyle elektrik devre modeli kullanılabilir.

2.3.1 Elektrokimyasal model

Gerçekçi batarya modelleri için ilk tercih elektrokimyasal modeldir (EM). Bu yöntem, bataryanın temel fiziksel ve kimyasal özelliklerini dikkate alarak batarya bozulmasını açık bir şekilde ortaya koymayı sağlar. Öte yandan, kısmi diferansiyel denklemler (PDE'ler) kullanıldığında, oldukça yüksek bir hesaplama maliyeti taşır ve zordur. Bu dezavantajlar, gerçek dünya senaryolarında uygulanabilirliğini sınırlar ve şarj durumu tahmini araştırmaları için daha az tercih edilen bir seçenek haline getirir [1].


2.3.2 Elektrik devre modelleri

Bataryaların çalışma prensiplerine dayalı olarak oluşturulan eşdeğer devre modelleri, lityum-iyon bataryaların nasıl çalıştığını anlamamıza yardımcı olur. Bu modeller sayesinde farklı batarya türlerini değerlendirmek mümkün olur. Araştırmacılar, lityum-iyon bataryalar için birçok benzer devre modeli geliştirmişlerdir. Günümüzde iki temel devre modelleme yaklaşımı bulunur: zaman alanı ve frekans alanı analiz modelleri. Zaman alanı analiz modeli, genellikle bataryanın voltaj ve akım verilerini kullanır. Frekans alanı analiz modeli ise bataryanın empedansını değerlendirmek için Nyquist ve Bode diyagramlarını kullanır. En yaygın kullanılan eşdeğer devre modellerini belirlemek için zaman alanı analizleri yapılır [14]

Bu tezin ana konuları RC Modeli, PNGV, Thevenin Modeli ve Değiştirilmiş Thevenin Modeli modelleridir.

2.3.2.1 RC modeli

Şekil 2.3'de görüldüğü gibi, bir RC modeli iki kapasitans ve üç dirençten oluşur. Li-ion bataryanın elektrik yükü depolama kapasitesi büyük kapasitans C_b ile, yüzey kapasitesi ve difüzyon etkisi küçük kapasitans C_s ile, terminal direnci R_t , yüzey direnci R_s ve uç direnci R_e ile açıklanır [15]




Şekil 2.3 : RC Modeli [14]

2.3.2.2 PNGV

Şekil 2.4'de gösterildiği gibi, Thevenin modeli, bir kondansatör C_o eklenerek PNGV modeline dönüştürülür. Bu modelde, ideal voltaj kaynağı OCV Li-ion bataryanın Açık Devre Voltajını (OCV) gösterir ve bu modelin benzersiz fiziksel bir anlamı vardır. Bataryanın direnci, ohmik iç direnci (R_O), polarizasyon iç direnci (R_p), polarizasyon kapasitesi (C_p), yük akımı (I_L), polarizasyon akımı (I_p), terminal voltajı (V_L) ve yük

akımının (I_L) zamanında entegrasyonundan kaynaklanan OCV'deki değişikliklerdir [14].




Şekil 2.4 : PNGV Modeli [14]

Li-ion bataryanın şarj veya deşarj olması sırasında zamanla akım birikimi, şarj durumunu değiştirir ve bunun sonucunda bataryanın OCV'sinde kondansatör C_o üzerindeki voltaj değişiklikleriyle gösterildiği gibi değişiklikler meydana gelir. Bu modeldeki kondansatör C_o , hem Li-ion bataryanın kapasitesini hem de doğrudan akım tepkisini temsil ederek Thevenin modelinin eksikliklerini telafi eder [14].

2.3.2.3 Thevenin modeli


Popüler modellerden biri olan Thevenin modeli, Şekil 2.5'de gösterilmiştir. Bu model, bir Li-ion bataryanın açık devre voltajını (OCV) açıklamak için ideal bir voltaj kaynağı kullanır. Ardından, belirli bir şarj durumunda ani bir yüke nasıl tepki vereceğini tahmin etmek için bir RC paralel ağı (R_p ve C_p) ve seri direnç R_o kullanır [3].



Şekil 2.5 : Thevenin Modeli [14]

2.3.2.4 Değiştirilmiş thevenin modeli

Araştırmacılar, dinamik performans gereksinimlerini karşılamak için her zaman yeterli olmayan tek kutuplu (unipolar) modeller yerine çeşitli iki kutuplu (bipolar) ve çok kutuplu (multipolar) modeller geliştirmiştir [16] Bu modellerden biri, Şekil 2.6'da gösterilen değiştirilmiş Thevenin modelidir. Bu modelde ideal voltaj kaynağı, lityum-iyon bataryanın açık devre voltajıdır (OCV). Modelin diğer bileşenleri şunlardır: elektrokimyasal polarizasyon kapasitansı (C_e), ohmik iç direnç (R_o), elektrokimyasal polarizasyon iç direnci (R_e), konsantrasyon polarizasyon iç direnci (R_c), konsantrasyon polarizasyon kapasitansı (C_c), elektrokimyasal polarizasyon voltajı (V_{C_e}), konsantrasyon polarizasyon voltajı (V_{C_c}), yük akımı (I_L) ve terminal voltajı (V_L) [14].



Şekil 2.6 : Değiştirilmiş Thevenin Modeli [14]

3 ŞARJ DURUMU TAHMİNLEME YÖNTEMLERİ

"SoC" veya "Şarj Durumu" terimi, bataryanın yaşlanma etkilerini en aza indirgeyecek şekilde çalıştırılmasını ve bataryanın aşırı deşarj olmasını veya aşırı şarj edilmesini önlemek için bataryadan çıkarılabilecek mevcut batarya kapasitesine atıfta bulunur [4].

Amper-saat (Ah) cinsinden ölçülen kapasite, bir bataryada depolanan belirli enerji miktarıdır. Bataryadaki aktif materyalin miktarına bağlı olarak, teorik kapasite, bataryadan çıkarılabilecek en büyük şarj miktarıdır. Bataryanın arta kalan kapasitesi, belirli bir yük ve sıcaklıkta deşarj ettikten sonra içinde kalan şarj miktarıdır. Tamamen şarj edilmiş bir bataryanın deşarj döngüsünün başında tam şarj kapasitesi, onun kalan kapasitesidir. Yeni bir hücrenin tamamen yüklü kapasitesi, onun tam tasarım kapasitesi olarak bilinir. Bir bataryanın maksimum kapasitesi, onun teorik kapasitesidir. Tamamen yüklü kapasite, genellikle batarya kapasitesinin doğrusal olmayan etkileri ve devre özelliklerinin doğrusal olmayan özellikleri nedeniyle teorik kapasiteden daha azdır [5]. Formül 3.1'de görüldüğü gibi nicel olarak ifade edilebilen Şarj durumu, bataryanın nominal şarj miktarının mevcut şarj miktarına oranı olarak tanımlanır.

$$SOC = \frac{Q_{kullanılabilir}}{Q_{nominal}} = \frac{\eta \int_0^{t_1} I_b(\tau) d\tau}{Q_{nominal}} \quad (3.1)$$

Burada, sırasıyla, η ve I_b , bataryanın şarj edilmiş akımının deşarj edilmiş akımından çıkarılmasıyla elde edilen net şarj akımı ve bataryanın verimliliğini temsil eder.

Bu çalışmada Şarj Durumu Tahminleme yöntemlerinden; Model Tabanlı ve Veriye Dayalı yöntemler incelenmiştir.

3.1 Model Bazlı Şarj Durumu Tahminleme Yöntemi

Bu çalışmada öncelikli olarak Model Tabanlı Şarj Durumu Tahminleme yöntemlerinden Voltaj Tabanlı Şarj Durumu Belirleme, Coulomb Sayma Yöntemiyle Şarj Durumu Belirleme ve diğer metodlar incelenmiştir.

3.1.1 Voltaj tabanlı şarj durumu belirleme

Şarj Durumlarının belirlenmesi, voltaja dayalı olarak oldukça kolaydır. Bu, şarj edilebilir pillerin, enerji seviyeleri düştükçe voltajlarının azalacağı varsayımına dayanır. Voltajın doğrusal olmayan düşüşüne rağmen, seviye tahmini için çeşitli noktalar seçilebilir ve bu noktalar doğrusallaştırma yöntemleriyle bölümlere

ayrılabilir. Pilin açık devre voltajını kullanarak, pilin mevcut durumu ile uygun şarj arasındaki bağlantıyı anlamak, Şarj Durumu seviyesini belirlememize olanak tanır. Bu metodoloji, genellikle düşük maliyetli ve yüksek maliyetli batarya göstergelerinde kullanılır [5] Hücrenin Şarj Durumunu belirlemek için voltajı ölçerek, şu ilişkiyi tanımlayabiliriz:

$$SoC = f^{-1}(OCV) \quad (3.2)$$

3.1.2 Coulomb sayma yöntemiyle şarj durumu belirleme

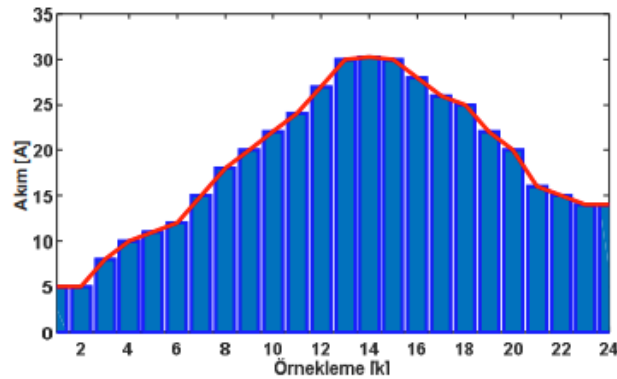
Endüstri, şarj durumu tahmini için CC (Coulomb Sayımı) yöntemini standartlaştırmıştır [17]. CC yöntemi, kısa vadeli hesaplamalar için en doğru teknik olduğundan, şu anda Şarj Durumu tahmini için en yaygın kullanılan yöntemdir (aynı zamanda amper-saat dengesi yöntemi olarak da bilinir). CC yöntemi ile şarj durumu şu şekilde tanımlanır:

$$SoC(t) = SoC(t_0) + \frac{1}{C_n} \int_{t_0}^{t+t_0} I_{bat}(d\tau) \times 100\% \quad (3.3)$$

I_{bat} , şarj/deşarj akımı, C_n nominal kapasite ve $SoC(t_0)$ ise başlangıçtaki Şarj Durumudur. CC basit bir yöntem olmasına rağmen, birikmiş hatalar ve başlangıç değeri hataları gibi dezavantajlara sahiptir, bu nedenle aşağıdaki hususlar göz önünde bulundurulmalıdır: Batarya akım ölçümleri, ölçüm gürültüsüne ve doğruluk eksikliklerine hassastır. Gürültü ve sensör çözünürlüğündeki veya yuvarlama hatalarındaki geniş aralık nedeniyle biriken hatalar, zamanla Denklem (3.3)'ün doğruluğunu kaybetmesine neden olur ve bunu önlemek için destekleyici algoritmalar gereklidir. Pratik uygulamada, başlangıçtaki şarj durumu bilinmeyebilir ve bir bataryanın şarj durumu, batarya sistemi termodinamik dengede olduğunda tanımlanabilir [17].

CC hesaplamasında şarj ve deşarj akımı zaman integrali kullanılır ve başlangıçtaki Şarj Durumu değeri bilinmelidir. Çoğu durumda, bu değerin bilinmediği varsayılır. Bu yöntem, başlangıçtaki şarj durumu değerine duyarlıdır ve kümülatif hatayı tamamen ortadan kaldıramaz. Başlangıçtaki şarj durumu değeri yanlışsa, tahmin sürecinin tamamında hatalar birikecektir ve tüm tahminler etkilenecektir. Son zamanlarda popülerlik kazanmış olmasına rağmen, CC genellikle şarj durumu tahmini için bağımsız bir yöntem olarak değil, diğer yöntemlerle birlikte kullanılır.

Zamanla geçerliliğini koruyan Coulomb sayım yöntemi, entegrasyon işlemlerini uygular. Coulomb sayımı için, gömülü mikrokontrolörlerin analog-dijital dönüştürücüler (ADC) aracılığıyla kullandığı örnekleme metodu, akım, paralel direnç veya osilasyon sensörü ölçümünü içerir. Güç kaybına sebebiyet vermemesi beklenen Hall dedektörleri gibi cihazlar, özellikle paralel dirençlerle karşılaştırıldığında, genellikle bataryalarda tercih edilir. Örnekleme tekniğine göre, Şekil 2.7’de Coulomb sayım yönteminin nasıl kullanıldığı gösterilmektedir.



Şekil 2.7 : Coulomb Sayım Yöntemi [18]

3.1.3 Diğer şarj durumu belirleme yöntemleri

Batarya doğrusal olmayan bir sistem olduğu için, şarj ve deşarj işlemleri, doğru bir matematiksel model oluşturmayı zorlaştırır. Sonuç olarak, doğrusal olmayan problemler için çözümler bulmak amacıyla yinelemeli yakınsama gibi yöntemler kullanılmaktadır. En popüler olanlarından biri, Kalman Filtresi tabanlı tekniklerdir. Bu tekniklerin yinelemeli yapısı, oldukça doğru şarj durumu tahminlerine olanak tanımaktadır [6].

3.1.3.1 Kalman filtresi

KF, yüksek hesaplama karmaşıklığı, şarj durumu ve sağlık durumu ölçme kapasitesi ve diğer avantajları nedeniyle son zamanlarda büyük ilgi görmüştür. KF'nin temel avantajı, önemli ölçüm varyasyonlarını ve rahatsızlıkları ortadan kaldırarak sistem durumlarını hassas bir şekilde tahmin edebilme yeteneğidir. KF, beklenen ve ölçülen değerleri ortalamak suretiyle girdi değeri belirsizliğini ortadan kaldırır [20].

3.1.3.2 Genişletilmiş kalman filtresi

Doğrusal olmayan sorunları ele almak ve ayrık Kalman filtresi oluşturmak için Genişletilmiş Kalman Filtresi (EKF), 1984 yılında tanıtılmıştır. EKF, ilk olarak sistem çıkışını ve hatayı kullanarak sistemin durumunu tahmin eder. Daha sonra bu bilgilere dayanarak mevcut durumlar düzeltilir [21].

3.2 Veriye dayalı şarj durumu tahminleme yöntemi

Şarj durumu tahmin yöntemlerinde, hesaplamayı kolaylaştırmak için algoritmalar sıklıkla veriye dayalı yöntemlerle birlikte kullanılmaktadır. Bu şarj durumu tahmin teknikleri, teknik yönlerine göre altı geniş kategoriye ayrılabilir: sınıflandırma/regresyon, bulanık mantık, hibrit, olasılıksal, geri dönüşümlü sinir ağları ve ileri beslemeli sinir ağları [22] Bu çalışmada, Destek Vektör Makineleri, XGBoost ve Derin Öğrenme, incelenen konular arasında yer almaktadır.

3.2.1 Destek vektör makineleri

Destek Vektör Makineler, regresyon ve sınıflandırma sorunlarını çözmek için veri kullanılan bir modeldir. SVM, yüksek boyutlu uzayda hiperdüzlemler oluşturarak bir sınıftan diğerine veri karakterizasyonu üretir. En yakın veri ile hiperdüzlem arasındaki mesafeyi azaltmak için optimal ayırım sınırı kullanılır. Pil şarj durumu hesaplama hata fonksiyonlarını azaltmada regresyon öğrenimi temel bir tekniktir [22].

3.2.2 XGBoost

2015 yılında, gradient boosting'den türetilen ölçeklenebilir bir teknik olan XGBoost geliştirildi. XGBoost, otomatik olarak ölçeklenebildiği ve gradient boosting'den 10 kat daha hızlı olduğu için genellikle eXtreme Gradient Boosting olarak adlandırılır. XGBoost, bagging işlemiyle benzer şekilde birçok modeli birleştirir. Hata oranını azaltmak için uygun bir model hakimiyeti artırma yöntemi uygulanır. Ayrıca, regularizasyon da aşırı uyum (overfitting) riskine karşı koruma sağlar [23]

3.2.3 Derin öğrenme


Bilgisayar bilimlerindeki derin öğrenme teorisini kullanarak, bir Li-ion bataryanın şarj durumu tahmini derin öğrenme yöntemi ile gerçekleştirilir. Bu yöntem, mevcut veriler ile girdi verileri (voltaj, akım, sıcaklık, güç, kapasite vb.) arasındaki ilişkiyi çıktı verisi şarj durumu açısından yaklaşık bir model oluşturur. Bu çalışmada Yapay Sinir Ağları (ANN), Evrişimli Sinir Ağları (CNN), Yinelemeli Sinir Ağları (RNN) ve Uzun-Kısa Vadeli Bellek (LSTM) işlenmiştir [2]

3.2.3.1 Yapay sinir ağları

Yapay sinir ağları (YSA), gelişimleri insan beyninin benzersiz işleyiş biçimlerinden ilham alsa da biyolojik karşılıklarıyla doğrudan bir ilişkisi yoktur. Biyolojik sinir ağları ve yapay sinir ağları, beyin kadar karmaşık olmasa da iki önemli özelliği paylaşır. İlk olarak, her iki ağ da temel, yoğun bir şekilde bağlantılı hesaplama cihazları üzerine kuruludur. Ayrıca, nöronların birbirine nasıl bağlandığı, ağın nasıl işlediğini belirler [24].

Yeterli veri ve uygun başlangıç koşulları sağlandığında, YSA'lar iç yapılarını en iyi sonuçları üretecek şekilde değiştirebilirler. Doğru girdiler verildiğinde, bir yapay sinir ağı çevresinden öğrenebilir ve zamanla bu bilgileri, bir insan beyni gibi, hatırlayabilir [12] Birçok çeşidi geliştirilmiş olan yapay sinir ağlarının, nasıl öğrendiklerine bağlı olarak iki ana sınıflandırması hızlıca belirlenebilir:

- Gözetimli Öğrenme (Supervised Learning): Bu kategori, "öğretmen" adı verilen bir kişinin, öğrenme aşamasında YSA'ya uygun davranışı "söylediği" veya performansını ne kadar iyi yaptığını belirttiği bir yaklaşımı içerir.
- Gözetimsiz Öğrenme (Unsupervised Learning): Bu kategorideki YSA'lar, veri setinin özelliklerini kendi başlarına inceler ve bu özellikleri çıktılarında nasıl temsil edeceklerini belirler.



Şekil 2.8 : Yapay Sinir Ağı (YSA) Mimarisi [25]

YSA'nın temelindeki formülleri inceleyecek olursak;

- Bir nöronun çıkışı (z), ağırlıklar (w), girdiler (x) ve bias (b) kullanılarak hesaplanır;

$$z = \sum_i (w_i \cdot x_i) + b \quad (3.4)$$

- Aktivasyon fonksiyonu (örneğin sigmoid) ile nöron çıkışının dönüştürülmesi

$$a = \frac{1}{1+e^{-z}} \quad (3.5)$$

- Ortalama karesel hata (MSE) kayıp fonksiyonu, gerçek değerler (y) ve tahminler (\hat{y}) arasındaki farkın karesinin ortalaması

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.6)$$

- Geri yayılım sırasında ağırlık güncellemesi, öğrenme oranı (η), gradyan (∇) ve kayıp fonksiyonu kullanılarak:

$$w_{new} = w_{old} - \eta \cdot \nabla J(w) \quad (3.7)$$

Şeklindedir.

3.2.3.2 Evrişimli sinir ağları

Makine öğrenmesinin bir alt kümesi olan Evrişimli Sinir Ağı (ESA), aynı zamanda Convolutional Neural Network (CNN) olarak da bilinir. Çeşitli türde veri ve uygulamalar için kullanılan yapay sinir ağlarının bir çeşididir. Derin öğrenme algoritmaları için bir CNN, özellikle piksel verilerinin işlenmesiyle ilgili görevlerde, örneğin görüntü tanıma gibi, kullanışlı olan bir ağ mimarisidir [26]


CNN'ler, derin öğrenmede nesne tanıma ve tanımlama için tercih edilen ağ mimarisidir, ancak başka türlerde sinir ağları da bulunmaktadır. Bu nedenle, yüz

tanıma ve otonom araçlar gibi kritik nesne tanıma uygulamalarında ve bilgisayarla görme (CV) görevlerinde idealdirler.

CNN, katmanlarından en az birinde, genel matris çarpımı yerine evrişim kullanır [26]

$$s(i, j) = (x * w)(i, j) = \sum_m \sum_n x(i - m, j - n)w(m, n) \quad (3.8)$$

Burada w , çekirdek matrisi ve x ise girdi matrisidir. Bir evrişimli sinir ağı oluşturmanın ve eğitimin ilk adımı, onun mimarisini tanımlamaktır. Farklı seviyeleri basitçe birleştirerek bir dizi katman oluşturulur. Tipik bir CNN yapısını oluşturan üç katman, evrişim katmanı, havuzlama katmanı ve tamamen bağlı katmandır [26] Şekil 2.9'de Evrişimli Sinir Ağı Mimarisi gösterilmiştir.



Şekil 2.9 : Evrişimli Sinir Ağı Mimarisi [27]

3.2.3.3 Yinelemeli sinir ağları


Konuşma tanıma ve doğal dil işleme alanlarında sıklıkla kullanılan yapay sinir ağlarından biri de Yinelemeli Sinir Ağıdır (YSA). Yinelemeli sinir ağları, bir diğer adıyla, Recurrent Neural Network (RNN), verinin ardışık özelliklerini tanımlamak için desenler kullanır ve olayların en olası seyrini öngörür.

RNN'ler, insan beynindeki nöron aktivitesini taklit eden modellerin oluşturulmasında ve derin öğrenmede kullanılır. Geri bildirim döngüleri aracılığıyla son çıktıyı bilgilendiren bir veri serisini işleyerek diğer yapay sinir ağları türlerinden farklı oldukları gibi, sonucu tahmin etmek için bağlamın önemli olduğu kullanım durumlarında özellikle etkilidirler. Bu tür ödül döngüleri, bilginin etrafta kalmasını sağlar ve bu etkiye genellikle hafıza denir [28].

Sinir ağıları, özellikle yinelemeli sinir ağıları, şarj durumu tahmini için bir dizi avantaj sunar, ancak büyük bir dezavantajları, istikrarlı bir çıktı elde etmek için uzun bir tarihsel veri dizisine ihtiyaç duymalarıdır. Veri döneminin başlangıcında, doğru bir şarj durumu tahmini mümkün değildir ve yakınsama benzeri bir süreç meydana gelir. Veri analiz süreci boyunca, genellikle tüm zaman dilimindeki her nokta için SOC tahmin etmek isteriz. Ancak, RNN kullanıldığında çıktı henüz istikrarlı olmadığı için, başlangıçtaki şarj durumu tahmini sonuçları atılmalıdır [29].

RNN'nin, doğru bir başlangıç şarj durumu olmadığında, tahmini sonuçların yakınsaması için bir dönem veriye ihtiyacı vardır. Bataryanın başlangıç aşamasının durum analizimiz, ağ topolojisine bağlı olarak değişen ve onlardan yüzlerce saniyeye kadar uzanabilen tarihsel veri gereksiniminin uzunluğundan etkilenmektedir [15].

Bu ağların iç katmanları tamamen bağlı olduğundan, girdi verilerinin uzunluğu sabit olmalı ve tahmin sürecinde kullanılan verilerin uzunluğu, eğitim sürecindekilerle eşleşmelidir. Tahmin edilen veriler eğitim setinden daha uzunsa, veriler kırpılmalıdır; tahmin edilen veriler eğitim setinden daha kısaysa, eğitilen model şarj durumu tahmini için kullanılamaz [29] Şekil 2.10'da Yinelemeli Sinir Ağı mimarisi gösterilmiştir.




Şekil 2.10 : Yinelemeli Sinir Ağı Mimarisi [31]

3.2.3.4 Uzun-Kısa vadeli bellek

Gradyan temelli öğrenme stratejisine sahip standart RNN'ler, boyut ve karmaşıklık arttıkça performans kaybı yaşarlar. İlk katmanlardaki parametreleri etkin bir şekilde ayarlamak aşırı emek yoğun ve hesaplama açısından maliyetli hale gelir [32].

Uzun kısa vadeli bellek (UKVB), bir diğer deyişle Long Short-Term Memory (LSTM) ağları, bu sorunu çözmek için geliştirilen bir yaklaşımdır; 1997 yılında bilgisayar bilimcileri Sepp Hochreiter ve Jurgen Schmidhuber tarafından geliştirilmiştir.

Hem RNN'ler hem de LSTM'ler, zaman serilerini analiz ederek belirli desenleri tanımlama ve depolama konusunda uzmanlaşmıştır ve bu desenler daha sonraki zaman adımlarında sonuçları tahmin etmek için kullanılır [33] RNN'lerin tasarımında temel geri bildirim döngülerine bağlı olarak verileri hafızada tutmasının aksine, LSTM'ler daha karmaşık hafıza yönetimi becerileri kazandıran ayrı bir hücre durumuna sahiptir, bu da hafızaya erişim ve değişiklik yapma işlemlerini içerir. LSTM hücre uygulamaları, popüler tüm makine öğrenimi çerçevelerinde mevcuttur [34]. Şekil 2.11'de Uzun kısa vadeli hafıza mimarisi gösterilmiştir.



Şekil 2.11 : Uzun Kısa Vadeli Hafıza Mimarisi [35]

4 DERİN ÖĞRENME YÖNTEMİYLE ŞARJ DURUMU TAHMİNLEME

Çalışmanın bu aşamasındaysa derin öğrenme metodlarıyla şarj durumu tahminlemeleri incelenmiştir. Bu tahminler gerçekleşmeden önce yapılması gereken çalışmalardan biri olan, veri seti seçilip bunu analizi ve temizlenme işlemleri gerçekleştirilmiştir. Devamında ise derin öğrenme metodlarının uygulanabilmesi için gerekli algoritmalar geliştirilmiş, veriye uygunluğu kesinleştikten sonra çalışmalar başlamıştır.

4.1 Veri Seti

Modelimizi oluşturmak için gerekli bilgileri içeren veri seti, satırlar ve sütunlar içeren tablo benzeri bir veri koleksiyonudur. Bu veri koleksiyonu içerisindeki satırlar ve sütunlar incelenmiş ve gerekli temizlik işlemleri gerçekleştirilmiştir.

Chen ve ark. (2020), P2D (Pseudo-two-dimensional) modeli kullanılarak yapılan simülasyonlar, deneysel sonuçlarla karşılaştırılmıştır. Bataryaya uygulanan akım profiline göre, P2D modeli bataryanın çıkış voltajını, iyon ve lityum

konsantrasyonlarını, akımları ve elektrot ile ayırıcı bölgelerindeki zaman ve uzamsal koordinatlara göre potansiyelleri tahmin etmek için kullanılmıştır. Özellikle, model tarafından tahmin edilen çıkış voltajı, deneysel voltaj ile karşılaştırılmıştır [36].

Bu deneysel veriler, 0 °C, 10 °C ve 25 °C'de ayarlanmış bir odada döngüye alınan üç farklı hücreden elde edilmiştir. Hücreler, 2.5 V ile 4.2 V arasında C/3 sabit akım-sabit voltaj (CC-CV) şarjı ve çeşitli sabit akım (CC) deşarj oranları (C/2, 1C ve 2.5C) ile döngüye alınmıştır. Şarj ve deşarj süreçleri, iki saatlik dinlenme periyotları ile takip edilmiştir [18].

Bu projede ise 0 °C, 10 °C ve 25 °C 'de deşarj oranları C/2, 1C ve 2.5C birleştirilerek analizler yapılmıştır.


4.2 Yapay Sinir Ağları Modelinin Geliştirilmesi

Tezin bu aşamasında ise Yapay Sinir Ağları modeli geliştirilmiş, ilgili algoritma sonuçları sunulmuştur. Öncelikle Keşifsel Veri Analizi yapılmış ve devamında veriye eğitim ve testler yapılmıştır. Son olarak da çıktılar alınmıştır.

4.2.1 Keşifsel Veri Analizi

EDA (Keşfedici Veri Analizi), veri seti değişkenlerinin ve bu değişkenler arasındaki etkileşimlerin daha iyi anlaşılmasını sağlar ve genellikle verilerin, formel modelleme veya hipotez testi faaliyetlerinin ötesinde ne açığa çıkarabileceğini incelemek için kullanılır. Ayrıca, veri analizi için kullanmayı düşündüğünüz istatistiksel yöntemlerin uygunluğunu belirlemede de yardımcı olabilir. Bu analiz, veri setinin yapısal özelliklerini anlamak ve verilerdeki olası desenleri veya anomalileri tespit etmek için önemli bir adımdır. Keşfedici veri analizi, veri setinin temel özelliklerini görselleştirmek ve analitik sürecin başlangıcında yararlı içgörüler elde etmek için kritik bir ön analiz yöntemidir.

Bu proje kapsamında ise 0 °C, 10 °C ve 25 °C'de deşarj oranları C/2, 1C ve 2.5C incelendiği belirtilmiştir. Bununla birlikte korelasyon matrisi de Şekil 4.1'de gösterildiği gibi çıkmıştır.



Şekil 4.1 : Korelasyon Matrisi

Bu Korelasyon Matrisi, batarya performansı ve özellikleriyle ilgili farklı değişkenler arasındaki lineer ilişkiyi göstermektedir. Detaylıca incelenecek olursa;

- **Gerilim (V) ve Amper-Saat (AhAccu):** 0.87 ile oldukça güçlü bir pozitif korelasyon göstermektedir. Bu, gerilim arttıkça bataryanın amper-saat kapasitesinin de arttığını gösterir ki bu, bataryanın yüksek gerilimlerde daha yüksek şarj depolama kapasitesini koruduğunu düşündürebilir.
- **Akım (A) ve Watt-saat (WhAccu):** Neredeyse mükemmel bir pozitif korelasyon olan 0.99 değeriyle, akımın watt-saat enerji kapasitesiyle hemen hemen mükemmel bir lineer ilişkisi olduğunu gösterir. Bu mantıklıdır çünkü watt-saatler doğrudan amper-saat (zamanla akım) ve gerilim işlevi olarak hesaplanır.
- **Sıcaklık (Temp Cell) ve Akım (A):** -0.71 ile güçlü negatif bir korelasyon gösterir ki bu, batarya hücresinin sıcaklığı arttıkça akım kapasitesinin azaldığını düşündürebilir. Bu durum artan iç dirence nedeniyle veya aşırı ısınmayı önlemek için güvenlik mekanizmalarının akımı azaltması sonucu olur.
- **Gerilim (V) ve Sıcaklık (Temp Cell):** -0.46 ile gösterilen güçlü negatif korelasyon, gerilim arttıkça hücre sıcaklığının azaldığını gösterir. Bu, yüksek gerilimlerin soğutma sistemi veya hücre kimyasının daha etkin çalıştığı durumları yansıtabilir veya batarya yönetim sisteminin aşırı ısınmayı önlemek için gerilimi düşürdüğü senaryoları işaret eder.

- **Watt (W) ve Sıcaklık (Temp Cell):** 1.00 ile mükemmel bir pozitif korelasyon göstermez; burada dikkat çeken -0.23 ile zayıf bir negatif ilişki vardır. Bu, güç çıkışının artmasının hücre sıcaklığını çok az bir şekilde azalttığı anlamına gelir.

Bu korelasyonlar, batarya yönetim sistemlerinin ve şarj durumu tahmin modellerinin geliştirilmesinde önemli etkenler olarak değerlendirilir. Özellikle, Akım ve Watt-Saat arasındaki yüksek korelasyon, şarj durumu tahminlerinin doğruluğunu arttırırken, Sıcaklık ile Akım ve Gerilim arasındaki negatif korelasyonlar, batarya sağlığı ve güvenliğinin yönetiminde kritik rol oynar

4.2.2 Eğitim ve Test

Bu aşamada ise 0 °C, 10 °C ve 25 °C'de deşarj oranları C/2, 1C ve 2.5C birleştirilerek ANN modeli kullanılarak eğitim ve testler gerçekleştirildi. Model eğitimi sırasında, veri setinin %80'i eğitim için, %20'si ise test için ayrıldı. Normalizasyon işlemi, modelin daha hızlı ve etkin öğrenmesini sağlamak amacıyla kullanıldı ve bu sayede farklı ölçeklerdeki değişkenlerin model tarafından eşit bir şekilde değerlendirilmesine olanak tanındı.

ANN modeli, zaman serileri tahmin problemi için diziler ve etiketler oluşturacak şekilde tasarlandı. Burada, bir 'lookback' penceresi kullanılarak, önceki zaman adımlarındaki değişken değerleri temel alınarak mevcut zaman adımındaki şarj durumu değeri tahmin edilmeye çalışıldı.

Modelin yapısı üç katmandan oluşmaktadır ve her bir katman, daha karmaşık özellikler çıkarmak için aktivasyon fonksiyonları kullanır. Dropout, modelin aşırı uyuma (overfitting) karşı dayanıklılığını artırmak için eklenmiştir.

Model eğitim süresince, her epoch için kayıp (loss) değeri hesaplanarak modelin performansı izlendi. Çizelge 3.1'de Epoch kayıplarının 15 aşamalı sonucu gözükmektedir.


Çizelge 4.1 : Epoch Kayıpları

Epoch Seviyesi	Kayıp
1/15	0.0018074229053041007
2/15	9.055709935099216e-05
3/15	5.085893148877269e-05
4/15	4.3042262113187795e-05
5/15	3.563303650064316e-05
6/15	2.8962593920480662e-05
7/15	2.513346147449728e-05
8/15	2.384163880828134e-05
9/15	2.3328193081550606e-05
10/15	2.2075229272096413e-05
11/15	1.951918204659176e-05
12/15	1.8111010903278473e-05
13/15	1.8666002570591794e-05
14/15	1.6105526020786224e-05
15/15	1.7045954826939835e-05

Bu kayıp değerleri, modelin eğitim veri seti üzerindeki hatalarının azaldığını ve bu nedenle öğrenme sürecinde ilerleme kaydettiğini gösterir.

- Eğitim Veri Setinde Şarj Durumu Tahmini**

Şekil 4.2’de, Yapay Sinir Ağları kullanılarak geliştirilen bir modelin eğitim veri seti üzerinde batarya Şarj Durumu değerlerini tahmin etme kabiliyetini göstermektedir.



Şekil 4.2 : Eğitim Veri Seti Üzerinde Şarj Durumu Tahmini


Eğitim sürecinde, modelin gerçek şarj durumu değerlerine (mavi çizgi) çok yakın tahminlerde (turuncu çizgi) bulunduğu görülmektedir. İki çizgi arasındaki uyum, modelin eğitim veri setindeki örüntüleri öğrenmede oldukça başarılı olduğunu göstermektedir.

Modelin performansını değerlendirmede kullanılan bu grafik, şarj durumunun zamanla nasıl değiştiğini ve modelin bu değişimi ne kadar iyi takip edebildiğini gözler önüne sermektedir. Şarj durumunun yüksek seviyelerden düşüşe geçtiği ve daha sonra tekrar yükseldiği noktalarda, modelin bu değişimleri yakalamada ve gerçek değerlere yakın sonuçlar üretmede oldukça etkili olduğu açıkça görülmektedir.

Grafiğin yorumlanması sırasında, modelin eğitim sürecindeki performansının yanı sıra, modelin aşırı uyum (overfitting) gösterip göstermediğini değerlendirmek de önemlidir. İki çizginin neredeyse mükemmel uyumu, gerçek dünya verileri üzerinde modelin genelleştirme kabiliyetinin doğrulanması gerektiğini gösterir.

- **Test Veri Setinde Şarj Durumu Tahmini**

Şekil 4.3'te, Yapay Sinir Ağları kullanılarak geliştirilen bir modelin test veri seti üzerinde batarya Şarj Durumu değerlerini tahmin etme kabiliyetini göstermektedir.



Şekil 4.3 : Test Veri Seti Üzerinde Şarj Durumu Tahmini

Gerçek şarj durumu değerleri ile model tarafından tahmin edilen şarj durumu değerleri arasındaki yakın uyum, modelin yeni ve daha önce görülmemiş veriler üzerindeki genelleştirme kapasitesinin güçlü olduğunu gösterir. Şarj durumu değerlerindeki keskin değişiklikleri modelin doğru bir şekilde yakaladığı ve bu dönüşümler boyunca gerçek değerlere sıkıca yapıştığı görülmektedir.

Grafikteki şarj durumu değerlerinde zamanla gözlemlenen keskin düşüş ve ardından gelen yükseliş, tipik olarak bir bataryanın deşarj ve tekrar şarj olma döngüsünü temsil eder. Model, bu döngünün her iki fazında da yüksek doğrulukla tahminler yapabilmektedir, ki bu da karmaşık dinamikler içeren sistemlerde ANN modelinin başarısını gösterir.

Grafikteki tahmin edilen değerlerin gerçek değerlere bu kadar yakın olması, modelin aşırı uyuma (overfitting) eğiliminde olmadığını da işaret eder.

Sonuç olarak, grafik, ANN tabanlı şarj durumu tahmin modelinin, batarya yönetim sistemleri ve şarj durumu izleme uygulamaları için güvenilir ve doğru sonuçlar sağlayabilecek potansiyeli olduğunu göstermektedir.

4.2.3 Değerlendirme

Son olarak da hem eğitim hem de test veri seti için Ortalama Mutlak Hata (MAE), Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) ve R kare (R^2) değerleri hesaplanmıştır. Çizelge 3.2 ve Çizgelde 3.3’de her veri seti için sonuçlar yer almaktadır.

Çizelge 4.2 : Eğitim Veri Seti için Metrikler

Metrik	Metrik Değeri
MAE	0.00374568
MSE	2.09493e-05
RMSE	0.004577043
R-kare (R^2)	0.999860219

Çizelge 4.3 : Test Veri Seti için Metrikler

Metrik	Metrik Değeri
MAE	0.007569746
MSE	7.294084e-05
RMSE	0.008540541
R-kare (R^2)	0.999575717

Eğitim Veri Seti için Metrikler:

- **Ortalama Mutlak Hata (MAE):** 0.0037 civarında bir değer, modelin tahminlerinin ortalama olarak gerçek değerlerden bu kadar birim sapma gösterdiğini ifade eder. Batarya şarj durumu tahminleri için bu düşük bir hata miktarıdır ve modelin oldukça doğru olduğunu gösterir.
- **Ortalama Kare Hata (MSE):** MSE değeri çok düşük ($2.09e-05$), bu da modelin hatalarının karelerinin ortalamasının çok düşük olduğunu gösterir. Düşük MSE, modelin tahminlerinin genel olarak gerçek değerlere oldukça yakın olduğunu gösterir.
- **Kök Ortalama Kare Hata (RMSE):** RMSE, MSE'nin kareköküdür ve hataların ölçeğini orijinal verilerin ölçeğine döndürür. 0.0045 civarında bir RMSE değeri, modelin ortalama hata büyüklüğünü ve modelin tutarlılığını gösterir.
- **R kare (R^2):** R^2 metriği, modelin verilerdeki varyansın ne kadarını açıkladığını gösterir. 0.9998 gibi yüksek bir değer, modelin verilerdeki varyansı neredeyse tamamen açıkladığını ve dolayısıyla çok yüksek bir doğrulukla tahminler yaptığını gösterir.

Test Veri Seti için Metrikler:

- **MAE:** Eğitim veri setine benzer şekilde, test veri setinde de MAE değeri düşüktür (0.0075), bu da modelin yeni veriler üzerindeki tahminlerinin de oldukça doğru olduğunu gösterir.
- **MSE:** Test veri setindeki MSE ($7.29e-05$) değeri, eğitim veri setine göre biraz daha yüksek olmasına rağmen yine de düşüktür ve modelin test setindeki tahminlerinin de oldukça iyi olduğunu gösterir.
- **RMSE:** RMSE değeri, test veri seti için 0.0085 olarak hesaplanmıştır, bu da modelin test veri setindeki tahminlerinin gerçek değerlerden bu kadar birim sapma gösterdiğini gösterir ve yine yüksek bir doğruluk düzeyini işaret eder.
- **R^2 :** Test veri seti için R^2 değeri 0.9995'tir, bu da modelin test veri setindeki verilerdeki varyansın neredeyse tamamını açıkladığını gösterir.


Bu metriklerin her ikisi de modelin hem eğitim hem de test veri setleri üzerinde mükemmel performans gösterdiğini göstermektedir. Modelin tutarlılığı ve genelleştirme kabiliyeti, bu metriklerle oldukça yüksek olarak değerlendirilebilir.

4.3 Evrişimli Sinir Ağları Geliştirilmesi

Tezin bu aşamasında ise Evrişimli Sinir Ağları modeli geliştirilmiş, ilgili algoritma sonuçları sunulmuştur. Öncelikle Keşifsel Veri Analizi yapılmış ve devamında veriye eğitim ve testler yapılmıştır. Son olarak da çıktılar alınmıştır.

4.3.1 Keşifsel Veri Analizi

EDA (Keşfedici Veri Analizi), bu proje kapsamında ise 0 °C, 10 °C ve 25 °C'de deşarj oranları C/2, 1C ve 2.5C incelendiği belirtilmiştir. Bununla birlikte korelasyon matrisi de Şekil 4.4'de gösterildiği gibi çıkmıştır.



Şekil 4.4 : Evrişimli Sinir Ağları İçim Korelasyon Matrisi

Bu Korelasyon Matrisi, batarya performansı ve özellikleriyle ilgili farklı değişkenler arasındaki lineer ilişkiyi göstermektedir. Detaylıca incelenecek olursa;

- **Gerilim (V) ve Amper-Saat (AhAccu):** 0.78 ile oldukça güçlü bir pozitif korelasyon göstermektedir. Bu, gerilim arttıkça bataryanın amper-saat kapasitesinin de arttığını gösterir ki bu, bataryanın yüksek gerilimlerde daha yüksek şarj depolama kapasitesini koruduğunu düşündürebilir.
- **Akım (A) ve Watt-saat (WhAccu):** Neredeyse mükemmel bir pozitif korelasyon olan 0.99 değeriyle, akımın watt ile hemen hemen mükemmel bir lineer ilişkisi

olduğunu gösterir. Bu mantıklıdır çünkü watt doğrudan akım ve gerilim işlevi olarak hesaplanır.

- **Sıcaklık (Temp Cell) ve Akım (A):** -0.45 ile orta derecede negatif bir korelasyon gösterir ki bu, batarya hücresinin sıcaklığı arttıkça akım kapasitesinin azaldığını düşündürebilir. Bu durum artan iç dirence nedeniyle veya aşırı ısınmayı önlemek için güvenlik mekanizmalarının akımı azaltması sonucu olur.
- **Gerilim (V) ve Sıcaklık (Temp Cell):** -0.28 ile gösterilen zayıf negatif korelasyon, gerilim arttıkça hücre sıcaklığının azaldığını gösterir. Bu, yüksek gerilimlerin soğutma sistemi veya hücre kimyasının daha etkin çalıştığı durumları yansıtabilir veya batarya yönetim sisteminin aşırı ısınmayı önlemek için gerilimi düşürdüğü senaryoları işaret eder.
- **Watt (W) ve Sıcaklık (Temp Cell):** -0.43 ile orta derecede negatif bir korelasyon gösterir. Bu, güç çıkışının artmasının hücre sıcaklığını azalttığı anlamına gelir.
- **Watt-Saat (WhAccu) ve Amper-Saat (AhAccu):** 0.94 ile oldukça güçlü bir pozitif korelasyon göstermektedir. Bu, watt-saatlerin amper-saatlerle doğrudan ilişkili olduğunu ve bataryanın enerji kapasitesinin akım ve gerilimle ilişkili olarak arttığını gösterir.

Bu korelasyonlar, batarya yönetim sistemlerinin ve şarj durumu tahmin modellerinin geliştirilmesinde önemli etkenler olarak değerlendirilir. Özellikle, akım ve watt-saat arasındaki yüksek korelasyon, şarj durumu tahminlerinin doğruluğunu arttırırken, sıcaklık ile akım ve gerilim arasındaki negatif korelasyonlar, batarya sağlığı ve güvenliğinin yönetiminde kritik rol oynamaktadır.

4.3.2 Eğitim ve Test

Bu aşamada, 0 °C, 10 °C ve 25 °C'deki deşarj oranları C/2, 1C ve 2.5C olarak birleştirilmiş ve CNN modeli kullanılarak eğitim ve testler gerçekleştirilmiştir. Modelin eğitimi sırasında, veri setinin %80'i eğitim, %20'si ise test için ayrılmıştır. Modelin daha hızlı ve etkin öğrenmesi için normalizasyon işlemi uygulanmış ve bu sayede farklı ölçeklerdeki değişkenler model tarafından eşit şekilde değerlendirilmiştir.

CNN modeli, zaman serisi tahmin problemleri için diziler ve etiketler oluşturacak şekilde yapılandırılmıştır. Bu aşamada, bir 'lookback' penceresi kullanılarak, geçmiş

zaman adımlarındaki değişken değerlerine dayanarak mevcut zaman adımındaki şarj durumu tahmin edilmiştir.

Model, birden fazla evrişimli katmandan oluşmakta olup, her bir katman daha karmaşık özellikler çıkarmak için ReLU aktivasyon fonksiyonlarını kullanmaktadır. İki evrişimli katman ve iki Max-Pooling katmanı içeren model, giriş verilerini işleyerek özellik çıkarımı gerçekleştirmektedir. Modelin aşırı uyum göstermesini önlemek için Dropout katmanı eklenmiştir.

Modelin eğitim süresince, her epoch için kayıp (loss) değeri hesaplanmış ve performansı izlenmiştir. Eğitim sürecinde RMSprop optimizasyon algoritması ve MSELoss kayıp fonksiyonu kullanılmıştır. Modelin performansı, eğitim ve test kayıpları üzerinden değerlendirilmiştir. Çizelge 3.4, 15 epoch boyunca kaydedilen kayıp değerlerini göstermektedir.


Çizelge 4.4 : Epoch Kayıpları

Epoch Seviyesi	Eğitim Kayıpları	Test Kayıpları
1/15	0.20399387918146562	0.34728187857841192
2/15	0.10800055177472039	0.28907744581384843
3/15	0.09655874583722745	0.19689430721941098
4/15	0.08744244038349926	0.10692962915010487
5/15	0.07096044762950975	0.92659996995545896
6/15	0.06143468595056135	0.45164159551365595
7/15	0.05429978868496664	0.20356242701643237
8/15	0.05209971426857395	0.38936444558893052
9/15	0.05068554686258063	0.34031753313611081
10/15	0.04695547924111635	0.22526564122173581
11/15	0.04609672657266493	0.26348313335929547
12/15	0.04496702536265476	0.16734990263882418
13/15	0.04357122581104144	0.19895362921810156
14/15	0.04513960115578118	0.23272687570005604
15/15	0.04177662030982514	0.21151668109058458

Bu kayıp değerleri, modelin eğitim veri seti üzerindeki hatalarının azaldığını ve bu nedenle öğrenme sürecinde ilerleme kaydettiğini gösterir.

- **Evrişimli Sinir Ağları Modeli ile Şarj Durumu Tahmini**

Şekil 4.5'te, Evrişimli Sinir Ağları kullanılarak geliştirilen bir modelin veri seti üzerinde batarya Şarj Durumu değerlerini tahmin etme kabiliyetini göstermektedir.



Şekil 4.5 : Test Veri Seti Üzerinde Şarj Durumu Tahmini

Eğitim sürecinde, modelin gerçek şarj durumu değerlerine (mavi çizgi) yakın tahminlerde (turuncu çizgi) bulunduğu gözlemlenmiştir. İki çizgi arasındaki uyum, modelin eğitim veri setindeki örüntüleri başarılı bir şekilde öğrendiğini göstermektedir. Ancak, bazı ani değişimlerin yaşandığı bölgelerde, tahminlerin gerçek değerlere kıyasla sapma gösterdiği de fark edilmektedir.

Modelin performansını değerlendirmek amacıyla kullanılan bu grafik, şarj durumunun zaman içerisindeki değişimini ve modelin bu değişimi ne kadar iyi takip edebildiğini göstermektedir. Şarj durumunun yüksek seviyelerden düşüşe geçtiği ve tekrar yükseldiği noktalarda, modelin bu değişimleri yakalamada belirli bir başarı gösterdiği, ancak bazı bölgelerde sapmalar yaşandığı görülmektedir.

Grafiğin yorumlanması sırasında, modelin eğitim sürecindeki performansının yanı sıra, modelin aşırı uyum (overfitting) gösterip göstermediğini değerlendirmek de önemlidir. Gerçek verilerle modelin tahminleri arasındaki bazı farklılıklar, modelin daha fazla optimize edilmesi gerektiğini ve gerçek dünya verileri üzerinde genelleştirme kabiliyetinin test edilmesi gerektiğini göstermektedir. Bu durum, test veri seti veya doğrulama veri seti üzerindeki performans analizi ile doğrulanabilir.

Sonuç olarak, CNN modeli SoC tahmininde genel olarak iyi bir performans sergilemekte, ancak bazı ani değişimlerde iyileştirme alanları bulunduğu açıkça görülmektedir. Bu analizler, modelin doğruluğunu artırmak için yapılacak gelecekteki çalışmalara ışık tutmaktadır

4.3.3 Değerlendirme

Son olarak da test veri seti için Ortalama Test Kaybı, Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) değerleri hesaplanmıştır. Çizelge 3.5’de veri seti için sonuçlar yer almaktadır.

Çizelge 4.5 : Test Veri Seti için Metrikler

Metrik	Metrik Değeri
Ortalama Test Kaybı	0.21151668109058458
MSE	0.2115524560213089
RMSE	0.45994833111763

Test Veri Seti için Metrikler:

- **Ortalama Test Kaybı:** Bu metrik, modelin test veri seti üzerindeki genel performansını gösterir. Düşük bir ortalama test kaybı, modelin test verileri üzerindeki tahminlerinin gerçek değerlere yakın olduğunu gösterir. Bu değerin 0.21151668109058458 olması, modelin test verisinde makul bir performans sergilediğini göstermektedir.
- **Ortalama Kare Hata (MSE):** Ortalama kare hata, tahmin edilen değerler ile gerçek değerler arasındaki farkın karesinin ortalamasını verir. Bu metrik, modelin doğruluğunu ölçmek için kullanılır. MSE'nin 0.2115524560213089 olması, tahmin edilen SoC değerlerinin gerçek SoC değerlerine oldukça yakın olduğunu ve modelin genel doğruluğunun iyi olduğunu gösterir.

- **Kök Ortalama Kare Hata (RMSE):** Kök ortalama kare hata, MSE'nin karekökü alınarak elde edilir ve tahmin hatalarının ortalama büyüklüğünü gösterir. RMSE, hataların gerçek birimlerde ifade edilmesini sağlar, bu nedenle daha yorumlanabilir bir metrik olarak kabul edilir. RMSE'nin 0.45994833111763 olması, modelin tahmin hatalarının ortalama büyüklüğünün yaklaşık olarak 0.46 Ah olduğunu gösterir. Bu değer, modelin tahminlerinin gerçek değerlere ne kadar yakın olduğunu anlamak için önemlidir.


Bu metrikler, modelin test veri setleri üzerinde mükemmel performans gösterdiğini göstermektedir. Düşük MSE ve RMSE değerleri, modelin SoC tahminlerinde başarılı olduğunu gösterir.

4.4 Yinelemeli Sinir Ağları Geliştirilmesi

Tezin bu aşamasında ise Yenilemeli Sinir Ağları modeli geliştirilmiş, ilgili algoritma sonuçları sunulmuştur. Öncelikle Keşifsel Veri Analizi yapılmış ve devamında veriye eğitim ve testler yapılmıştır. Son olarak da çıktılar alınmıştır

4.4.1 Keşifsel Veri Analizi

EDA (Keşfedici Veri Analizi), bu proje kapsamında ise 0 °C, 10 °C ve 25 °C'de deşarj oranları C/2, 1C ve 2.5C incelendiği belirtilmiştir. Bununla birlikte korelasyon matrisi de Şekil 4.6'da gösterildiği gibi çıkmıştır.



Şekil 4.6 : Yinelemeli Sinir Ağları Korelasyon Matrisi

Bu Korelasyon Matrisi, batarya performansı ve özellikleriyle ilgili farklı değişkenler arasındaki lineer ilişkiyi göstermektedir. Detaylıca incelenecek olursa;

- **Gerilim (V) ve Amper-Saat (AhAccu):** 0.77 ile güçlü bir pozitif korelasyon göstermektedir. Bu, gerilim arttıkça bataryanın amper-saat kapasitesinin de arttığını gösterir. Yani, bataryanın yüksek gerilimlerde daha yüksek şarj depolama kapasitesini koruduğunu düşündürebilir.
- **Akım (A) ve Watt-saat (WhAccu):** 0.99 değeriyle neredeyse mükemmel bir pozitif korelasyon göstermektedir. Bu, akımın watt-saat enerji kapasitesiyle hemen hemen mükemmel bir lineer ilişkisi olduğunu gösterir. Bu durum mantıklıdır çünkü watt-saatler, doğrudan amper-saat (zamanla akım) ve gerilim işlevi olarak hesaplanır.
- **Sıcaklık (Temp Cell) ve Akım (A):** -0.45 ile orta düzeyde negatif bir korelasyon göstermektedir. Bu, batarya hücresinin sıcaklığı arttıkça akım kapasitesinin azaldığını düşündürebilir. Bu durum, artan iç direnç nedeniyle veya aşırı ısınmayı önlemek için güvenlik mekanizmalarının akımı azaltması sonucu olabilir.
- **Gerilim (V) ve Sıcaklık (Temp Cell):** -0.26 ile zayıf negatif bir korelasyon göstermektedir. Bu, gerilim arttıkça hücre sıcaklığının azaldığını gösterir. Bu durum, yüksek gerilimlerin soğutma sistemi veya hücre kimyasının daha etkin çalıştığı durumları yansıtabilir veya batarya yönetim sisteminin aşırı ısınmayı önlemek için gerilimi düşürdüğü senaryoları işaret edebilir.
- **Watt (W) ve Sıcaklık (Temp Cell):** -0.43 ile orta düzeyde bir negatif korelasyon göstermektedir. Bu, güç çıkışının (Watt) artmasıyla hücre sıcaklığının (Temp Cell) azaldığını gösterir. Bu durum, bataryanın güç çıkışı arttıkça soğutma mekanizmalarının etkinleşmesi veya güç çıkışının sıcaklığı düşüren bir etkisi olabileceğini düşündürebilir.

Bu korelasyonlar, batarya yönetim sistemlerinin ve şarj durumu tahmin modellerinin geliştirilmesinde önemli etkenler olarak değerlendirilir. Özellikle, akım ve watt-saat arasındaki yüksek korelasyon, şarj durumu tahminlerinin doğruluğunu arttırırken, sıcaklık ile akım ve gerilim arasındaki negatif korelasyonlar, batarya sağlığı ve güvenliğinin yönetiminde kritik rol oynar.

4.4.2 Eğitim ve Test

Bu aşamada, 0 °C, 10 °C ve 25 °C'deki deşarj oranları C/2, 1C ve 2.5C olarak birleştirilmiş ve RNN modeli kullanılarak eğitim ve testler gerçekleştirilmiştir. Modelin eğitimi sırasında, veri setinin %80'i eğitim, %20'si ise test için ayrılmıştır. Modelin daha hızlı ve etkin öğrenmesi için normalizasyon işlemi uygulanmış ve bu sayede farklı ölçeklerdeki değişkenler model tarafından eşit şekilde değerlendirilmiştir.

RNN modeli, zaman serisi tahmin problemleri için diziler ve etiketler oluşturacak şekilde yapılandırılmıştır. Bu aşamada, bir 'lookback' penceresi kullanılarak, geçmiş zaman adımlarındaki değişken değerlerine dayanarak mevcut zaman adımındaki şarj durumu tahmin edilmiştir. Model, birden fazla yenilemeli katmandan oluşmakta olup, her bir katman daha karmaşık zaman serisi ilişkilerini öğrenmek için tasarlanmıştır. RNN katmanları, zaman içindeki ardışık verileri işleyerek özellik çıkarımı gerçekleştirmektedir. Modelin aşırı uyum göstermesini önlemek için Dropout katmanı eklenmiştir.

Modelin eğitim süreci boyunca, her epoch için eğitim ve test kayıpları hesaplanmış ve izlenmiştir. Eğitim sürecinde RMSprop optimizasyon algoritması ve MSELoss kayıp fonksiyonu kullanılmıştır. Modelin performansı, eğitim ve test kayıpları üzerinden değerlendirilmiştir. Çizelge 3.6, 15 epoch boyunca kaydedilen kayıp değerlerini göstermektedir.

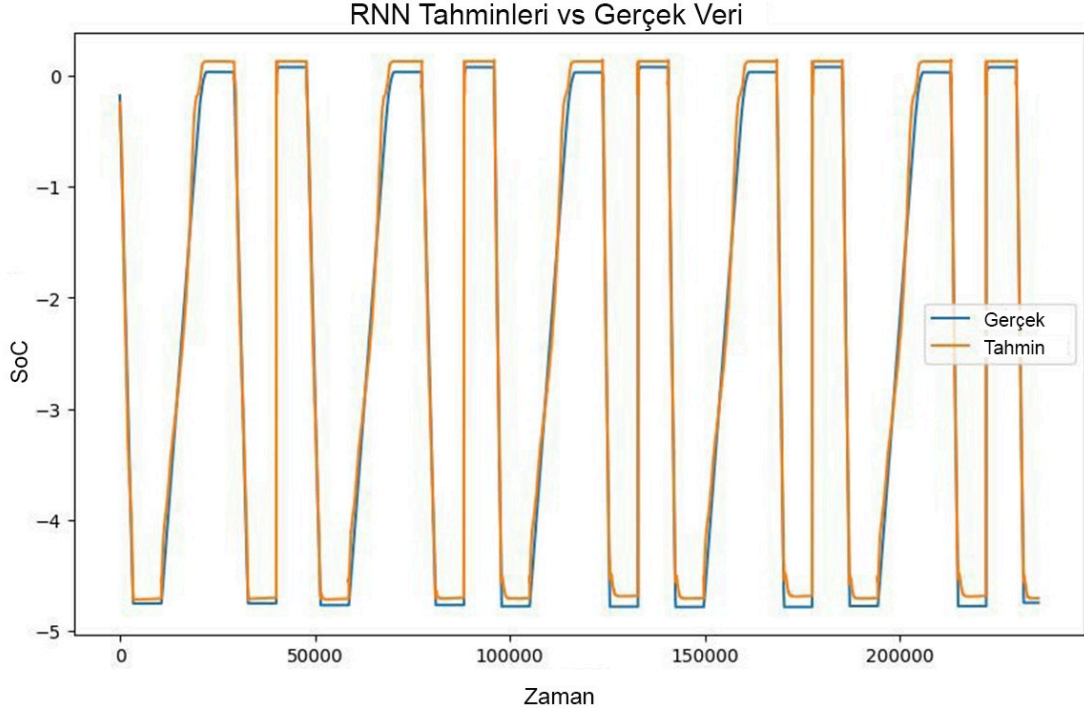
Çizelge 4.6 : Epoch Kayıpları

Epoch Seviyesi	Eğitim Kayıpları	Test Kayıpları
1/15	0.11650495040949987	1.1455438751386247
2/15	0.07723630305804562	1.2744834500118591
3/15	0.07549101044978238	1.3450846178783792
4/15	0.07476260726110678	1.3297728408579903

RNN modelinin eğitim sürecinde erken durdurma (Early Stopping) mekanizması kullanılmıştır. Bu mekanizma, modelin aşırı uyumunu önlemek amacıyla, belirli bir sayıda epoch boyunca test kayıplarında iyileşme olmadığında eğitimi durdurur. Bu çalışmada, erken durdurma mekanizması 3 epoch boyunca test kayıplarında iyileşme olmadığında eğitimi durdurmuştur. Bu, modelin aşırı uyum göstermesini önlemiş ve eğitimin gereksiz yere uzun sürmesini engellemiştir.

- **Yinelemeli Sinir Ağları Modeliyle Şarj Durumu Tahmini**

Şekil 4.7’de, Yinelemeli Sinir Ağları kullanılarak geliştirilen bir modelin test veri seti üzerinde batarya Şarj Durumu değerlerini tahmin etme kabiliyetini göstermektedir.



Şekil 4.7 : Yinelemeli Sinir Ağları Modeliyle Şarj Durumu Tahmini

Eğitim sürecinde, modelin gerçek şarj durumu değerlerine (mavi çizgi) oldukça yakın tahminlerde (turuncu çizgi) bulunduğu gözlemlenmiştir. İki çizgi arasındaki uyum, modelin eğitim veri setindeki örüntüleri başarılı bir şekilde öğrendiğini göstermektedir. Modelin özellikle hızlı değişim gösteren bölgelerde bile doğru tahminler yapabilmesi, eğitim sürecinin verimli geçtiğini ve modelin bu tür değişimleri yakalayabildiğini göstermektedir.

Modelin performansını değerlendirmek amacıyla kullanılan bu grafik, şarj durumunun zaman içerisindeki değişimini ve modelin bu değişimi ne kadar iyi takip edebildiğini göstermektedir. Şarj durumunun yüksek seviyelerden düşüşe geçtiği ve tekrar yükseldiği noktalarda, modelin bu değişimleri yakalamada belirli bir başarı gösterdiği açıkça görülmektedir.

Grafiğin yorumlanması sırasında, modelin eğitim sürecindeki performansının yanı sıra, modelin aşırı uyum (overfitting) gösterip göstermediğini değerlendirmek de önemlidir. İki çizginin neredeyse mükemmel uyumu, modelin eğitim verilerinde yüksek bir doğruluk sağladığını, ancak bu durumun test veri seti üzerinde de doğrulanması gerektiğini göstermektedir.

Sonuç olarak, RNN modeli SoC tahmininde genel olarak iyi bir performans sergilemektedir.

4.4.3 Değerlendirme

Son olarak da test veri seti için Ortalama Test Kaybı, Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) değerleri hesaplanmıştır. Çizelge 3.7’de veri seti için sonuçlar yer almaktadır.

Çizelge 4.7 : Test Veri Seti için Metrikler

Metrik	Metrik Değeri
Ortalama Test Kaybı	0.021655343443
MSE	0.021612353453
RMSE	0.147022421132

Test Veri Seti için Metrikler:

- **Ortalama Test Kaybı:** Bu değerın düşük olması, modelin test verileri üzerindeki tahminlerinin gerçek değerlere oldukça yakın olduğunu gösterir. 0.021655343443 değerindeki ortalama test kaybı, modelin doğru tahminlerde bulunabildiğini ve genellikle başarılı bir performans sergilediğini göstermektedir.
- **Ortalama Kare Hata (MSE):** Bu metrik, modelin doğruluğunu ölçmek için kullanılır. MSE'nin 0.021612353453 olması, tahmin edilen SoC değerlerinin gerçek SoC değerlerine oldukça yakın olduğunu ve modelin genel doğruluğunun iyi olduğunu gösterir.


- **Kök Ortalama Kare Hata (RMSE):** RMSE, hataların gerçek birimlerde ifade edilmesini sağlar, bu nedenle daha yorumlanabilir bir metrik olarak kabul edilir. RMSE'nin 0.147022421132 olması, modelin tahmin hatalarının ortalama büyüklüğünün yaklaşık olarak 0.147022421132 olduğunu gösterir. Bu değer, modelin tahminlerinin gerçek değerlere ne kadar yakın olduğunu anlamak için önemlidir.

4.5 Uzun-Kısa Vadeli Bellek Sinir Ağları Geliştirilmesi

Tezin bu aşamasında ise Uzun-Kısa Vadeli Bellek Sinir Ağları modeli geliştirilmiş, ilgili algoritma sonuçları sunulmuştur. Öncelikle Keşifsel Veri Analizi yapılmış ve devamında veriye eğitim ve testler yapılmıştır. Son olarak da çıktılar alınmıştır.

4.5.1 Keşifsel Veri Analizi

Bu proje kapsamında ise 0 °C, 10 °C ve 25 °C'de deşarj oranları C/2, 1C ve 2.5C incelendiği belirtilmiştir. Bununla birlikte korelasyon matrisi de Şekil 4.8'de gösterildiği gibi çıkmıştır.



Şekil 4.8 : Uzun-Kısa Vadeli Bellek Sinir Ağları Korelasyon Matrisi

Bu Korelasyon Matrisi, batarya performansı ve özellikleriyle ilgili farklı değişkenler arasındaki lineer ilişkiyi göstermektedir. Detaylıca incelenecek olursa;

- **Gerilim (V) ve Amper-Saat (AhAccu):** 0.78 ile güçlü bir pozitif korelasyon göstermektedir. Bu, gerilim arttıkça bataryanın amper-saat kapasitesinin de arttığını gösterir. Bu durum, bataryanın yüksek gerilimlerde daha yüksek şarj depolama kapasitesini koruduğunu düşündürülebilir.
- **Akım (A) ve Watt-saat (WhAccu):** 0.99 değeriyle neredeyse mükemmel bir pozitif korelasyon göstermektedir. Bu, akımın watt-saat enerji kapasitesiyle hemen hemen mükemmel bir lineer ilişkisi olduğunu gösterir. Bu durum mantıklıdır çünkü watt-saatler doğrudan amper-saat (zamanla akım) ve gerilim işlevi olarak hesaplanır.
- **Sıcaklık (Temp Cell) ve Akım (A):** -0.45 ile orta düzeyde negatif bir korelasyon göstermektedir. Bu, batarya hücresinin sıcaklığı arttıkça akım kapasitesinin azaldığını düşündürülebilir. Bu durum, artan iç direnç nedeniyle veya aşırı ısınmayı önlemek için güvenlik mekanizmalarının akımı azaltması sonucu olabilir.
- **Gerilim (V) ve Sıcaklık (Temp Cell):** -0.27 ile zayıf negatif bir korelasyon göstermektedir. Bu, gerilim arttıkça hücre sıcaklığının azaldığını gösterir. Bu durum, yüksek gerilimlerin soğutma sistemi veya hücre kimyasının daha etkin çalıştığı durumları yansıtabilir veya batarya yönetim sisteminin aşırı ısınmayı önlemek için gerilimi düşürdüğü senaryoları işaret edebilir.
- **Watt (W) ve Sıcaklık (Temp Cell):** -0.43 ile orta düzeyde negatif bir ilişki göstermektedir. Bu, güç çıkışının artmasıyla hücre sıcaklığının azaldığını gösterir. Bu durum, bataryanın güç çıkışı arttıkça soğutma mekanizmalarının etkinleşmesi veya güç çıkışının sıcaklığı düşüren bir etkisi olabileceğini düşündürülebilir.

Bu korelasyonlar, batarya yönetim sistemlerinin ve şarj durumu tahmin modellerinin geliştirilmesinde önemli etkenler olarak değerlendirilir. Özellikle, Akım ve Watt-Saat arasındaki yüksek korelasyon, şarj durumu tahminlerinin doğruluğunu arttırırken, Sıcaklık ile Akım ve Gerilim arasındaki negatif korelasyonlar, batarya sağlığı ve güvenliğinin yönetiminde kritik rol oynar

4.5.2 Eğitim ve Test

Bu aşamada, 0 °C, 10 °C ve 25 °C'deki deşarj oranları C/2, 1C ve 2.5C olarak birleştirilmiş ve LSTM modeli kullanılarak eğitim ve testler gerçekleştirilmiştir. Modelin eğitimi sırasında, veri setinin %80'i eğitim, %20'si ise test için ayrılmıştır. Modelin daha hızlı ve etkin öğrenmesi için normalizasyon işlemi uygulanmış ve bu

sayede farklı ölçeklerdeki değişkenler model tarafından eşit şekilde değerlendirilmiştir.

LSTM modeli, zaman serisi tahmin problemleri için diziler ve etiketler oluşturacak şekilde yapılandırılmıştır. Bu aşamada, bir 'lookback' penceresi kullanılarak, geçmiş zaman adımlarındaki değişken değerlerine dayanarak mevcut zaman adımındaki şarj durumu tahmin edilmiştir. Model, birden fazla LSTM katmanından oluşmakta olup, her bir katman daha karmaşık zaman serisi ilişkilerini öğrenmek için tasarlanmıştır. LSTM katmanları, zaman içindeki ardışık verileri işleyerek özellik çıkarımı gerçekleştirmektedir. Modelin aşırı uyum göstermesini önlemek için Dropout katmanı eklenmiştir.

Modelin yapılandırılması, nöron sayısı, katman sayısı ve dropout oranı gibi hiperparametrelerin belirlenmesi için Optuna kullanılarak optimize edilmiştir. Optuna, 20 deneme boyunca en iyi hiperparametre kombinasyonunu belirlemiştir. Belirlenen en iyi hiperparametrelerle model yeniden yapılandırılmış ve eğitim sürecine başlanmıştır.

Eğitim sürecinde, modelin performansı her epoch için eğitim ve test kayıpları üzerinden değerlendirilmiştir. Eğitim süresince RMSprop optimizasyon algoritması yerine Adam optimizasyon algoritması ve MSELoss kayıp fonksiyonu kullanılmıştır. Çizelge 3.8’de Epoch kayıplarının 15 aşamalı sonucu gözükmemektedir.


Çizelge 4.8 : Epoch Kayıpları

Epoch Seviyesi	Eğitim Kayıpları	Test Kayıpları
1/15	0.31176749270048283	0.14690862601752708
2/15	0.07801316253181902	0.08665448246085883
3/15	0.07699822193802422	0.09222682758985778
4/15	0.07639796105619141	0.07486589598790386
5/15	0.07579389361842185	0.08093406256674401
6/15	0.07550114410264584	0.06484440943184339
7/15	0.07412390850510263	0.12540070564457128
8/15	0.07220506142947632	0.35202333558792829
9/15	0.06974630512753222	0.70211268498482044
10/15	0.06223968201293546	0.60975577856605735
11/15	0.05405145675997643	0.43116061727259823
12/15	0.05211045324938664	0.43667568488700065
13/15	0.05046188425638275	0.45853511232676146
14/15	0.05066246677761133	0.24609058820979612
15/15	0.04875291322805699	0.18564304903500098

Bu kayıp değerleri, modelin eğitim veri seti üzerindeki hatalarının azaldığını ve bu nedenle öğrenme sürecinde ilerleme kaydettiğini gösterir.

- **Uzun-Kısa Vadeli Bellek Sinir Ağları Modeli ile Şarj Durumu Tahmini**

Şekil 4.9’da Uzun-Kısa Vadeli Bellek Sinir Ağları kullanılarak geliştirilen bir modelin eğitim veri seti üzerinde batarya Şarj Durumu değerlerini tahmin etme kabiliyetini göstermektedir.



Şekil 4.9 : Uzun-Kısa Vadeli Bellek Sinir Ağları Modeli ile Şarj Durumu Tahmini

Grafik incelendiğinde, modelin tahmin ettiği değerler (turuncu çizgi) büyük ölçüde gerçek değerleri (mavi çizgi) takip etmektedir. Bu, modelin genel olarak doğru tahminler yaptığını ve SoC tahmininde başarılı olduğunu göstermektedir.

Eğitim sürecinde, modelin gerçek şarj durumu değerlerine yakın tahminlerde bulunduğu gözlemlenmiştir. İki çizgi arasındaki uyum, modelin eğitim veri setindeki örüntüleri öğrenmede oldukça başarılı olduğunu göstermektedir. Modelin özellikle hızlı değişim gösteren bölgelerde bile doğru tahminler yapabilmesi, eğitim sürecinin verimli geçtiğini ve modelin bu tür değişimleri yakalayabildiğini göstermektedir.

Modelin performansını değerlendirmek amacıyla kullanılan bu grafik, şarj durumunun zaman içerisindeki değişimini ve modelin bu değişimi ne kadar iyi takip edebildiğini göstermektedir. Şarj durumunun yüksek seviyelerden düşüşe geçtiği ve tekrar yükseldiği noktalarda, modelin bu değişimleri yakalamada belirli bir başarı gösterdiği açıkça görülmektedir. Bu, modelin ani değişikliklere hızlı tepki verebildiğini ve gerçek değerlere yakın tahminlerde bulunabildiğini göstermektedir.

Grafığın yorumlanması sırasında, modelin eğitim sürecindeki performansının yanı sıra, modelin aşırı uyum (overfitting) gösterip göstermediğini değerlendirmek de önemlidir. İki çizginin neredeyse mükemmel uyumu, modelin eğitim verilerinde yüksek bir doğruluk sağladığını, ancak bu durumun test veri seti üzerinde de doğrulanması gerektiğini göstermektedir. Test veri seti veya doğrulama veri seti üzerindeki performans analizi, modelin genelleştirme kabiliyetini değerlendirmek için kritiktir.

Sonuç olarak, LSTM modeli SoC tahmininde genel olarak iyi bir performans sergilemekte, ancak bu performansın test verileri üzerinde de doğrulanması gerekmektedir. Bu analizler, modelin doğruluğunu ve güvenilirliğini artırmak için yapılacak gelecekteki çalışmalara ışık tutmaktadır.

4.5.3 Değerlendirme

Son olarak da test veri seti için Ortalama Test Kaybı, Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) değerleri hesaplanmıştır. Çizelge 3.9’da test veri seti için sonuçlar yer almaktadır.

Çizelge 4.9 : Test Veri Seti için Metrikler

Metrik	Metrik Değeri
Ortalama Test Kaybı	0.000948148362179355
MSE	0.000948362692724913
RMSE	0.030795497819781303

Test Veri Seti için Metrikler:

- **Ortalama Test Kaybı:** Bu değerin düşük olması, modelin test verileri üzerindeki tahminlerinin gerçek değerlere oldukça yakın olduğunu gösterir. 0.000948148362179355 değerindeki ortalama test kaybı, modelin doğru tahminlerde bulunabildiğini ve genellikle başarılı bir performans sergilediğini göstermektedir.
- **Ortalama Kare Hata (MSE):** Bu metrik, modelin doğruluğunu ölçmek için kullanılır. MSE'nin 0.0009483626927249134 olması, tahmin edilen SoC değerlerinin gerçek SoC değerlerine oldukça yakın olduğunu ve modelin genel doğruluğunun iyi olduğunu gösterir.
- **Kök Ortalama Kare Hata (RMSE):** RMSE'nin 0.030795497819781303 olması, modelin tahmin hatalarının ortalama büyüklüğünün yaklaşık olarak 0.0308 Ah olduğunu gösterir. Bu değer, modelin tahminlerinin gerçek değerlere ne kadar yakın olduğunu anlamak için önemlidir.

Bu metrikler, LSTM modelinizin test veri seti üzerindeki performansını değerlendirmenize yardımcı olur ve modelin genel doğruluğu hakkında bilgi sağlar. Düşük MSE ve RMSE değerleri, modelin SoC tahminlerinde başarılı olduğunu gösterir. Bu da modelin, batarya şarj durumu tahminlerinde güvenilir bir araç olduğunu ortaya koyar.

5 SONUÇLAR VE TARTIŞMA

Tezin bu aşamasında yapılan çalışmaların karşılaştırmalı analizi gerçekleştirilmiş, kullanılan sinir ağıları sonuçlarının performansları yorumlanmış ve geleceğe dönük tavsiyeler verilmiştir.

5.1 Karşılaştırmalı Analiz

Bu çalışmanın amacı, batarya şarj durumu (SoC) tahmini için kullanılan farklı derin öğrenme modellerinin (ANN, CNN, RNN ve LSTM) performanslarını karşılaştırmak ve analiz etmektir. Modellerin eğitim ve test süreçlerinde elde edilen metrikler değerlendirilmiş ve genel sonuçlar tartışılmıştır. Çizelge 3.10'da ilgili modellerin sonuçları karşılaştırmalı analiz sonuçları olarak verilmiştir.

Çizelge 5.1 : Karşılaştırmalı Analiz Sonuçları

Model	MSE	RMSE
ANN	7.294084e-05	0.008540541
CNN	0.2115524560213089	0.45994833111763
RNN	0.021612353453	0.147022421132
LSTM	0.0009483626927249134	0.030795497819781303

5.2 Performans Yorumları

Çalışmanın bu kısmında ise modellerin performans yorumları yapıp gerekli karşılaştırmalar yapılmıştır.

5.2.1 LSTM'nin Verimi

LSTM modeli, düşük MSE ve RMSE değerleri ile en yüksek doğruluğa ulaşmıştır. Uzun dönem bağımlılıkları ve dizileri etkin bir şekilde işleyebilmesi, bu modelin en başarılı olmasını sağlamıştır. LSTM modeli, SoC tahmininde yüksek doğruluk ve güvenilirlik gerektiren uygulamalar için önerilir.

5.2.2 CNN'nin Zorlukları

CNN modelleri, uzamsal özellikleri tanımda başarılı olsa da zamansal bağımlılıkları yakalamada yetersiz kalmıştır. Bu modelin performansı, zaman serisi verileri için ek düzenlemeler yapılmadan diğer modellere göre daha düşüktür. Temporal konvolüsyonların eklenmesi veya RNN/LSTM ile hibrit yapıların kullanılması performansı artırabilir.

5.2.3 RNN'nin Potansiyeli

RNN modelleri, kısa vadeli zamansal bağımlılıkları yakalamada başarılı olmuştur. Ancak, uzun dizilerde vanishing gradient sorunları nedeniyle performans sınırlıdır. LSTM'nin bu sorunları çözmesi, RNN modellerinin performansını artırabilecek potansiyel iyileştirmeleri göstermektedir.

5.2.4 ANN'nin Basitliği

ANN modelleri, basit yapıları sayesinde iyi performans göstermiştir. Ancak, karmaşık zamansal ilişkileri yakalamada yetersiz kalmıştır. SoC tahmininde daha karmaşık modellerin (RNN, LSTM) daha iyi sonuçlar verdiği gözlemlenmiştir.

5.3 Sonuçlar

Bu çalışma, veriye dayalı yöntemlerin yanı sıra Şarj Durumu tahmin algoritmalarını ve ayrıca Destek Vektör Makineleri, XGBoost ve Derin Öğrenme tekniklerini de kapsamlı bir şekilde ele almaktadır. Ayrıca, Ani Deşarj Kapasitesi değerlerinin tahmini, Yapay Sinir Ağları tekniği kullanılarak gerçekleştirilmiş ve elde edilen sonuçlar, Ortalama Test Hatası, Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) değerleri açısından analiz edilip karşılaştırılmıştır.

Öte yandan, laboratuvar koşullarında LG M50 Bataryasının farklı sıcaklık dereceleri ve farklı C-rate'lerde gerçekleştirilen ölçümleri, bu alanda yapılan çalışmaların sınırlılığını göstermektedir. Mevcut datasetlerin bu çalışmalara olan katkısı göz önünde bulundurulduğunda, bu proje kapsamında 0 °C, 10 °C ve 25 °C'de deşarj oranları ve C/2, 1C ve 2C ölçümleri ve testleri yapılmıştır.

Çıkan sonuçlara dayanarak, batarya şarj durumu tahmin görevlerinde LSTM modellerinin kullanılması önerilir. Yüksek doğruluk ve güvenilirlik gerektiren uygulamalar için bu modelin tercih edilmesi, daha doğru ve güvenilir sonuçlar elde edilmesini sağlar.

6 KAYNAKLAR

- [1] “Explained: The Battery System,” <https://embatterysystems.com/blog/what-is-a-battery-system/>.
- [2] M. A. Hannan *et al.*, “Deep learning approach towards accurate state of charge estimation for lithium-ion batteries using self-supervised transformer model,” *Sci Rep*, vol. 11, no. 1, Dec. 2021, doi: 10.1038/s41598-021-98915-8.
- [3] E. Ipek, “A NOVEL METHOD TO ESTIMATE STATE OF CHARGE OF LI-BASED BATTERIES”.
- [4] P. Kurzweil, “Gaston Planté and his invention of the lead–acid battery—The genesis of the first practical rechargeable battery,” *J Power Sources*, vol. 195, no. 14, pp. 4424–4434, Jul. 2010, doi: 10.1016/j.jpowsour.2009.12.126.
- [5] Ş. EFE and Z. A. GÜNGÖR, “Geçmişten Günümüze Batarya Teknolojisi,” *European Journal of Science and Technology*, Jan. 2022, doi: 10.31590/ejosat.1048673.
- [6] P. Bäuerlein, C. Antonius, J. Löffler, and J. Kümpers, “Progress in high-power nickel–metal hydride batteries,” *J Power Sources*, vol. 176, no. 2, pp. 547–554, Feb. 2008, doi: 10.1016/j.jpowsour.2007.08.052.
- [7] S. Lee, J. Kim, J. Lee, and B. H. Cho, “State-of-charge and capacity estimation of lithium-ion battery using a new open-circuit voltage versus state-of-charge,” *J Power Sources*, vol. 185, no. 2, pp. 1367–1373, Dec. 2008, doi: 10.1016/j.jpowsour.2008.08.103.
- [8] Ö. F. Özcan, T. Karadağ, M. Altuğ, and Ö. Özgüven, “Elektrikli Araçlarda Kullanılan Pil Kimyasallarının Özellikleri ve Üstün Yönlerinin Kıyaslanması Üzerine Bir Derleme Çalışması,” *Gazi University Journal of Science Part A: Engineering and Innovation*, vol. 8, no. 2, Jun. 2021.
- [9] “LİTYUM İYON PİLLER (Lİ-LON),” <https://www.procyon.com.tr/blog/216/lityum-iyon-piller-li-lon/>.
- [10] G. Zubi, R. Dufo-López, M. Carvalho, and G. Pasaoglu, “The lithium-ion battery: State of the art and future perspectives,” *Renewable and Sustainable Energy Reviews*, vol. 89, pp. 292–308, Jun. 2018, doi: 10.1016/j.rser.2018.03.002.
- [11] G.-W. Yoo, B.-C. Jang, and J.-T. Son, “Novel design of core shell structure by NCA modification on NCM cathode material to enhance capacity and cycle life for lithium secondary battery,” *Ceram Int*, vol. 41, no. 1, pp. 1913–1916, Jan. 2015, doi: 10.1016/j.ceramint.2014.09.077.
- [12] B. Balasingam, M. Ahmed, and K. Pattipati, “Battery management systems-challenges and some solutions,” *Energies (Basel)*, vol. 13, no. 11, Jun. 2020, doi: 10.3390/en13112825.
- [13] “Batarya Yönetim Sistemi,” <https://imbelectric.com/batarya-yonetim-sistemi-nedir/>.
- [14] X. Zhang, W. Zhang, and G. Lei, “A Review of Li-ion Battery Equivalent Circuit Models,” *Transactions on Electrical and Electronic Materials*, vol. 17, no. 6, pp. 311–316, Dec. 2016, doi: 10.4313/TEEM.2016.17.6.311.
- [15] H. Hinz, “Comparison of Lithium-Ion Battery Models for Simulating Storage Systems in Distributed Power Generation,” *Inventions*, vol. 4, no. 3, p. 41, Aug. 2019, doi: 10.3390/inventions4030041.
- [16] X. Hu, S. Li, and H. Peng, “A comparative study of equivalent circuit models for Li-ion batteries,” *J Power Sources*, vol. 198, pp. 359–367, Jan. 2012, doi: 10.1016/j.jpowsour.2011.10.013.

- [17] J. P. Rivera-Barrera, N. Muñoz-Galeano, and H. O. Sarmiento-Maldonado, "Soc estimation for lithium-ion batteries: Review and future challenges," *Electronics (Switzerland)*, vol. 6, no. 4. MDPI AG, Dec. 01, 2017. doi: 10.3390/electronics6040102.
- [18] E. İ. Tezde and H. İ. Okumuş, "Batarya Modelleri ve Şarj Durumu (SoC) Belirleme Battery Models and State of Charge (SoC) Determination."
- [19] M. Korkmaz, "Kalman Filtresi Parametre Değişimlerinin Batarya SoC Tahmini Üzerine Etkileri." [Online]. Available: <http://as-proceeding.com/Konya,Turkeyhttps://www.icaens.com/>
- [20] X. Cui, Z. Jing, M. Luo, Y. Guo, and H. Qiao, "A new method for state of charge estimation of lithium-ion batteries using square root cubature kalman filter," *Energies (Basel)*, vol. 11, no. 1, 2018, doi: 10.3390/en11010209.
- [21] "ding-et-al-2016-simultaneous-identification-of-structural-parameter-and-external-excitation-with-an-improved-unscented".
- [22] D. V. S. R. Sesidhar, C. Badachi, and R. C. Green, "A review on data-driven SOC estimation with Li-Ion batteries: Implementation methods & future aspirations," *Journal of Energy Storage*, vol. 72. Elsevier Ltd, Nov. 25, 2023. doi: 10.1016/j.est.2023.108420.
- [23] T. , H. T. , B. M. , K. V. and T. Y. Chen, "Xgboost: extreme gradient boosting," *R package version*, vol. 0.4-2, 2015.
- [24] Y. S. Park and S. Lek, "Artificial Neural Networks: Multilayer Perceptron for Ecological Modeling," in *Developments in Environmental Modelling*, vol. 28, Elsevier B.V., 2016, pp. 123–140. doi: 10.1016/B978-0-444-63623-2.00007-4.
- [25] N. KOÇ USTALI, N. TOSUN, and Ö. TOSUN, "Makine Öğrenmesi Teknikleri İle Hisse Senedi Fiyat Tahmini," *Eskişehir Osmangazi Üniversitesi İktisadi ve İdari Bilimler Dergisi*, vol. 16, no. 1, pp. 1–16, Apr. 2021, doi: 10.17153/oguiibf.636017.
- [26] H. S. Bhattacharyya, A. Yadav, A. B. Choudhury, and C. K. Chanda, "Convolution Neural Network-Based SOC Estimation of Li-ion Battery in EV Applications," in *2021 5th International Conference on Electrical, Electronics, Communication, Computer Technologies and Optimization Techniques, ICEECCOT 2021 - Proceedings*, Institute of Electrical and Electronics Engineers Inc., 2021, pp. 587–592. doi: 10.1109/ICEECCOT52851.2021.9708055.
- [27] "6.6. Evrişimli Sinir Ağları (LeNet)," https://tr.d2l.ai/chapter_convolutional-neural-networks/lenet.html.
- [28] A. DAYAN and A. YILMAZ, "Modelling the machines' language with natural language processing and machine learning algorithms," *DÜMF Mühendislik Dergisi*, Jul. 2022, doi: 10.24012/dumf.1131565.
- [29] X. Fan, W. Zhang, C. Zhang, A. Chen, and F. An, "SOC estimation of Li-ion battery using convolutional neural network with U-Net architecture," *Energy*, vol. 256, Oct. 2022, doi: 10.1016/j.energy.2022.124612.
- [30] F. Yang, W. Li, C. Li, and Q. Miao, "State-of-charge estimation of lithium-ion batteries based on gated recurrent neural network," *Energy*, vol. 175, pp. 66–75, May 2019, doi: 10.1016/j.energy.2019.03.059.
- [31] A. Amidi and S. Amidi, "Tekrarlayan Yapay Sinir Ağları el kitabı," <https://stanford.edu/~shervine/l/tr/teaching/cs-230/cheatsheet-recurrent-neural-networks>.
- [32] P. IEEE Industrial Electronics Society. Conference (45th : 2019 : Lisbon, Universidade Nova de Lisboa, Institute of Electrical and Electronics

- Engineers, and IEEE Industrial Electronics Society, *Proceedings, IECON 2019-45th Annual Conference of the IEEE Industrial Electronics Society : Convention Center, Lisbon, Portugal, 14-17 October, 2019*.
- [33] Institute of Electrical and Electronics Engineers and IEEE Signal Processing Society, *SLT 2014 : 2014 IEEE Workshop on Spoken Language Technology : proceedings : December 7-10, 2014, Harvey's Lake Tahoe Casino/Hotel, South Lake Tahoe, Nevada, U.S.A.*
 - [34] M. Verleysen, Université catholique de Louvain, Katholieke Universiteit Leuven, C. I. and M. L. 23 2015. 04. 23-25 B. European Symposium on Artificial Neural Networks, and ESANN 23 2015.04.23-25 Bruges, *Proceedings / 23rd European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning, ESANN 2015, Bruges, Belgium, April 22-23-24, 2015*. Ciaco, 2015.
 - [35] P. Hu, J. Qi, J. Bo, Y. Xia, C.-M. Jiao, and M.-T. Huang, "Research on LSTM-Based Industrial Added Value Prediction Under the Framework of Federated Learning," in *Proceedings of the 2022 3rd International Conference on Big Data and Informatization Education (ICBDIE 2022)*, Dordrecht: Atlantis Press International BV, 2023, pp. 426–434. doi: 10.2991/978-94-6463-034-3_44.
 - [36] C.-H. Chen, F. Brosa Planella, K. O'Regan, D. Gastol, W. D. Widanage, and E. Kendrick, "Development of Experimental Techniques for Parameterization of Multi-scale Lithium-ion Battery Models," *J Electrochem Soc*, vol. 167, no. 8, p. 080534, Jan. 2020, doi: 10.1149/1945-7111/ab9050.

ÖZGEÇMİŞ

7



Ad Soyad: Turan Can Büyükkamacı

Doğum Yeri ve Tarihi: İzmir, Türkiye, 07/08/2000

Adres: Şişli, İstanbul, Türkiye

Lisans Üniversitesi: İstanbul Teknik Üniversitesi

